

Detecció de Comportament i Estimació de Pes de Porcs amb Visió 2D i 3D: Pastor Digital

Pere Llauradó Adeva

Resum— L'augment de prop d'un 20% de la població porcina a la Península Ibèrica durant els últims 10 anys fa inviable que els ramaders, sense els recursos tecnològics adequats, puguin controlar el benestar, l'activitat i el pes de cadascun dels animals. Aquest projecte busca entrenar models d'IA capaces d'automatitzar el monitoratge de l'activitat i el benestar del bestiar, amb l'objectiu d'apropar aquesta tecnologia a les petites explotacions per millorar-ne la competitivitat, alhora que permet a les grans instal·lacions optimitzar l'eficiència i garantir el benestar dels porcs. A més, a causa de les dificultats en l'obtenció de dades necessàries per a predir el pes, s'ha investigat el camp dels Espais de Dades amb del *Federated Learning* i s'ha creat una representació a petita escala. Aquesta iniciativa de la Unió Europea permet la col·laboració entre diferents empreses per entrenar models d'intel·ligència artificial sense necessitat de compartir explícitament les seves dades, ni dependre de les dades d'una sola empresa. Gràcies a la recerca duta a terme en aquest projecte, s'ha desenvolupat un model altament precís i robust, capaç d'operar en diferents granges, condicions de lluminositat i genètica de porcs.

Paraules clau— Ramaderia de Precisió, Visió per Computador, Xarxes Neuronals Convolucionals, Espais de Dades, Aprenentatge Federat, Visió 3D, Estimació de Pes, Benestar Animal.

Abstract— The nearly 20% increase in the pig population across the Iberian Peninsula over the last decade makes it unfeasible for farmers lacking adequate technological resources to monitor the welfare, activity, and weight of each individual animal. This project aims to train AI models capable of automating the monitoring of livestock activity and welfare, with the goal of making this technology accessible to small-scale farms to enhance their competitiveness, while enabling larger facilities to optimize efficiency and ensure pig welfare. Furthermore, due to the difficulties in acquiring the necessary data to predict weight, the field of Data Spaces along with Federated Learning has been investigated, leading to the creation of a small-scale representation. This European Union initiative allows for collaboration among different companies to train artificial intelligence models without the need to explicitly share their data or depend on a single company's dataset. Thanks to the research conducted in this project, a highly accurate and robust model has been developed, capable of operating across diverse farms, lighting conditions, and pig breeds.

Index Terms— Precision Livestock Farming, Computer Vision, Convolutional Neural Networks, Data Spaces, Federated Learning, 3D Vision, Weight Estimation, Animal Welfare.

1 INTRODUCCIÓ - CONTEXT DEL TREBALL

EL meu avi, que va ser pastor i ramader de xais des dels 6 anys, podia dir per experiència si un animal estava malalt, estressat o tenia problemes de creixement a ull nu, sense cap mena de tecnologia. Actualment, se sacrifiquen més de 52 milions de porcs només a l'Estat espanyol, i la població porcina ha augmentat més d'un 133% en els últims 28 anys. Davant d'aquest augment desmesurat, és molt important garantir el benestar de cada animal durant la seva estada a la granja; però, avui dia, som incapaços de vigilar i garantir aquest benestar a simple vista.

Al mateix temps, a la carnisseria de la meua mare puc presenciar la pressió que rep aquest sector. El preu del porc no ha parat d'augmentar, sent un dels productes que més ha impulsat la inflació alimentària i arribant a registrar increments interanuals d'un 13,6% segons l'IPC [2]. A més, el consumidor exigeix cada cop una producció més ètica i amb certes certificacions que garanteixin el benestar animal. Amb uns costos de producció tan disparats, els marges de benefici tant de carnisseres com de grangers s'estan reduint de manera preocupant. Com es pot assegurar una vida digna als animals sense ofegar econòmicament els ramaders?

Aquest TFG proposa crear un "pastor digital" mitjançant tècniques d'Intel·ligència Artificial i Visió per Computador (utilitzant dades 2D i 3D de l'IRTA [1] i el CVC) per monitorar de forma autònoma el comportament, la salut i el pes dels porcs. Així, la tecnologia esdevé una solució pràctica i no invasiva per garantir el benestar animal i, alhora, millorar la rendibilitat econòmica de les granges.

- E-mail de contacte: pllauradon@gmail.com
- Menció realitzada: Computació
- Treball tutoritzat per: Coen Antens (visió per computació)
- Curs 2025/26

2 CONTEXTUALITZACIÓ I OBJECTIUS

Aquest Treball de Final de Grau neix d'una gran motivació personal per aportar valor, des de l'enginyeria, a un sector estretament lligat als meus orígens familiars, com he explicat anteriorment. Actualment, el monitoratge a les explotacions ramaderes es realitza en gran mesura de manera manual, la qual cosa resulta costosa i necessita molta mà d'obra. Per resoldre aquesta problemàtica, aquest projecte se centra en el disseny i desenvolupament d'un sistema basat en Intel·ligència Artificial per a l'anàlisi automatitzada del comportament i l'estimació de pes de porcs en diferents granges, utilitzant imatges 2D i 3D capturades en col·laboració amb l'IRTA [1] i el CVC. Per assolir aquesta fita, l'abast del treball es desglossa en els objectius específics següents, els quals integren les motivacions clau del projecte:

- **Millora del benestar animal:** adquirir les dades necessàries per a cada animal per poder millorar la vida dels porcs.
- **Optimització del rendiment ramader:** desenvolupar els algorismes necessaris de *Deep Learning* per classificar patrons de comportament i estimar el pes a partir de dades 3D. Això permetrà reduir la dependència de l'observació manual, fent el sistema més escalable i millorant els marges de benefici de l'explotació.
- **Desenvolupament de models de Visió per Computador:** Tractar les dades 2D i les 3D, entrenar i implementar models de segmentació avançats capaços d'identificar de manera individualitzada cada animal dins dels corrals, fins i tot en situacions complexes d'alta oclusió.
- **Avaluació i comparativa tècnica:** realitzar un estudi comparatiu de rendiment i cost computacional entre diferents arquitectures per a la detecció, així com l'avaluació d'algorismes avançats de seguiment (*tracking*) i reidentificació (Re-ID) per determinar la solució tecnològica més òptima per a l'entorn real.

3 PLANIFICACIÓ I METODOLOGIA

Per a l'organització d'aquest TFG s'ha optat per una adaptació de la metodologia àgil (*Agile*). El treball s'estructurarà en 4 *Sprints* de 5 setmanes cadascun, corresponent-se cada un amb les entregues corresponents.

Per a la planificació diària de les tasques, es farà ús d'un tauler *Kanban* mitjançant *Trello* [3]. A més a més, el desenvolupament tècnic s'ha dut a terme a *Google Colab* [23] mantenint un històric i el codi final es trobarà a GitHub [6].

Tal com es pot observar de manera visual al Diagrama de Gantt (Apèndix A1), el flux de treball s'ha estructurat de la manera següent:

Sprint 1: Fonamentació i Planificació (Febrer - Març)

Aquest primer cicle correspon a la fase introductòria i "filosofal" del projecte. S'ha dedicat a entendre el problema, establir l'abast tècnic, preparar les eines de gestió (*Trello* i repositoris) i estructurar el treball. Aquesta fase conclou amb el lliurament de l'Informe Inicial (Setmana 4).

Sprint 2: Inici Tècnic i Visió 2D (Març - Abril)

Inici del desenvolupament pràctic. Va des de la neteja i etiquetatge de les imatges, fins a l'inici de l'entrenament dels primers models CNN amb les dades 2D per detectar les siluetes dels porcs de manera individual. Finalitza amb el lliurament de l'Informe de Progrés I (Setmana 10).

Sprint 3: Integració 3D i Comportament (Abril - Maig)

Aquesta iteració es focalitza en incloure el tractament de les imatges 3D i la preparació de l'entorn per a calcular el pes. A més a més, es desenvoluparà un Espai de Dades per a millorar el rendiment del model 2D. La fita d'aquest cicle és el lliurament de l'Informe de Progrés II (Setmana 14).

Sprint 4: Avaluació i Tancament (Maig - Juny)

L'últim esprint es destina exclusivament a l'anàlisi de resultats, al desenvolupament d'una interfície senzilla per avisar els veterinaris i grangers, i a la redacció de la memòria completa. Per a aquesta darrera etapa s'haurà d'entregar el Lliurament Final (abans del 29 de juny) i la Defensa Pública (del 3 al 8 de juliol).

4 ESTAT DE L'ART

Per contextualitzar les decisions tecnològiques preses durant el desenvolupament d'aquest projecte, és necessari realitzar una revisió de l'estat actual. A continuació, es detallen els diferents models, xarxes neuronals i algorismes matemàtics que formen la base teòrica del treball, dividits segons la seva finalitat pràctica.

4.1 Models de Detecció i Segmentació

Aquesta categoria engloba les arquitectures encarregades de localitzar els objectes i extreure'n la silueta en un fotograma estàtic.

- **Mask R-CNN:** Arquitectura de detecció de dues etapes que assoleix una alta precisió geomètrica a nivell de píxel. Tot i això, té un elevat cost computacional, que la fa inviable per processar vídeo en temps real en dispositius de granja.[7].
- **SSD (Single Shot MultiBox Detector):** Model d'una sola etapa que assoleix grans velocitats

generant prediccions en una única passada. Malgrat la seva agilitat, presenta dificultats per detectar objectes petits o altament densos en comparació amb altres arquitectures [8].

- **YOLO (*You Only Look Once*):** És la família de models d'una sola etapa més utilitzada en la indústria actual. YOLO analitza la imatge dividint-la en una quadrícula per processar la detecció com un únic problema de regressió, aconseguint resultats pràcticament instantanis. En les seves versions més recents, com YOLOv8, incorpora segmentació de màscares molt precises, oferint un equilibri òptim entre cost computacional i rendiment operatiu [5].

4.2 Associació temporal

Aquests elements permeten a l'ordinador relacionar i recordar l'aspecte dels diferents individus.

- **Hungarian Algorithm:** És un mètode matemàtic clàssic d'optimització dissenyat per resoldre problemes d'assignació. En el seguiment d'objectes, s'utilitza per emparellar de manera eficient les deteccions del fotograma actual amb les trajectòries conegudes del fotograma anterior. L'algorisme busca la combinació que minimitzi el cost global de l'assignació, que habitualment es calcula en funció de la distància física entre els objectes [9].
- **Auto Encoder:** És una xarxa neuronal no supervisada dissenyada per aprendre a comprimir i representar dades de manera eficient. Funciona forçant la informació visual d'entrada a passar per un procés de compressió, reduint-la a un vector de característiques (*embedding*), per després intentar reconstruir-la. En l'àmbit de la visió artificial, s'utilitza com a eina per extreure els trets visuals més importants d'una imatge descartant-ne el soroll, permetent així diferenciar i recordar l'aspecte únic de cada animal [10].
- **Re-Identification (ReID):** És el mòdul encarregat de reconèixer la identitat d'un mateix individu al llarg del temps o a través de diferents càmeres. El sistema extreu un vector de característiques visuals úniques de l'animal, basant-se en la textura o el color. Així, quan un porc pateix una oclusió i torna a ser visible, el mòdul compara els vectors emmagatzemats per confirmar si es tracta del mateix individu [11].

4.3 Algorismes de tracking

Els algorismes MOT (Multi-Object Tracking) fusionen les deteccions espacials amb els mètodes d'associació per assignar identificadors (IDs) continus als vídeos.

- **SORT (*Simple Online and Realtime Tracking*):**

Algorisme de seguiment extremadament ràpid basat en Filtres de Kalman i l'Algorisme Hongarès. Tot i la seva gran eficiència computacional, es descarta a causa de la seva vulnerabilitat davant d'oclusions, fet que provoca constants intercanvis i pèrdues d'identitat [12].

- **Deep SORT:** Evolució directa de SORT desenvolupada per mitigar els errors d'oclusió. La seva gran aportació és la integració d'un mòdul descriptor d'aparença profunda (ReID) basat en una xarxa neuronal, permetent relacionar els objectes tant per posició com per característiques visuals [13].
- **ByteTrack:** Millora als anteriors no descartant automàticament les deteccions de baixa confiança. En lloc d'eliminar-les, les recupera en un procés d'associació secundari, aconseguint mantenir trajectòries estables durant oclusions complexes [15].
- **BoT-SORT (*Robust Associations Multi-Object Tracking*):** Aquest model millora DeepSORT integrant un sistema de compensació del moviment de la càmera (CMC) i un mòdul ReID molt avançat. Tot i que proporciona una gran estabilitat en la conservació dels IDs, la seva alta càrrega de processament penalitza significativament la quantitat de fotogrames per segon (FPS), dificultant el seu ús en directe de forma pràctica [14].

4.4 Models de dataspace

Dataspace amb Federated Learning: Les dades es mantenen confinades a les granges locals i l'única informació que viatja cap al nexa central és el coneixement matemàtic extret per la xarxa neuronal, millorant molt el rendiment i escalabilitat i mantenint una privacitat total per a les empreses. D'aquesta manera evites tenir una arquitectura centralitzada on concentres totes les dades a un servidor central. [19][22]

5 DESENVOLUPAMENT

A continuació, es detallen els procediments duts a terme per assolir amb èxit els objectius establerts a l'apartat 2. Aquest capítol recull tota l'evolució tècnica del projecte separada en diferents apartats, des del processament de les dades 2D, l'entrenament dels models de segmentació, la creació dels espais de dades i seguiment, fins a la implementació de l'estimació del pes dels animals en temps real.

5.1 Desenvolupament 2D

Per tal d'aprofitar al màxim el temps de desenvolupament, la primera part d'entrenament i optimització del model s'ha dut a terme amb un dataset reduït provinent d'una granja d'anys anteriors. Un cop l'IRTA ha proporcionat les imatges actuals, s'ha entrenat i avaluat el model amb una major quantitat d'imatges per a obtenir-ne la versió definitiva.

5.1.1 Preparació del dataset

La fase d'ajustament inicial s'ha dut a terme utilitzant vídeos d'arxiu de l'any 2021 de la Granja experimental, Lleida CEP, corresponents a un corral amb 10 porcs. Per a la preparació d'aquestes dades, s'ha programat un script en *Python*, fent ús de la llibreria *OpenCV* [16], que extreu fotogrames automàticament cada 25 segons. Aquest mostreig temporal s'ha aplicat amb l'objectiu d'obtenir imatges el més diverses possible, evitant la similitud entre fotogrames consecutius per prevenir problemes de *underfitting* i *overfitting*, obtenint un total de 100 imatges.

Seguidament, s'han etiquetat manualment les siluetes dels animals mitjançant l'aplicació web *CVAT* [17]. Per agilitzar el procés, aquesta eina s'ha combinat amb el model de segmentació *SAM 3* de Meta [18], fet que ha permès generar les màscares d'entrenament de manera molt més ràpida i precisa com es pot veure a la *Figura 1*. D'aquesta manera, s'ha preparat un primer dataset de 86 imatges d'entrenament i validació.



Figura 1: Imatge processada per SAM a la interfície CVAT.

Més endavant, quan s'han obtingut els vídeos definitius de la granja experimental de l'IRTA [1] Monells, s'ha preparat el dataset principal, amb molt més volum d'imatges. S'ha aplicat el mateix procediment d'etiquetatge que en la fase anterior, però utilitzant fins a 220 imatges. S'han seleccionat els vídeos i trossos més complexos manualment per a poder-li oferir al model diferents situacions d'oclusió, lluminositat i varietat.

5.1.2 Entrenament models de segmentació 2D

Un cop preparat i etiquetat el conjunt de dades inicial, s'ha procedit a l'entrenament dels models. Després d'investigar diverses possibilitats per a crear un model basat en xarxes neuronals convolucionals (CNN) [7], s'ha determinat que, pel volum de dades disponible, i cercant un equilibri entre rendiment, resultats ràpids i alta precisió, l'arquitectura *YOLOv8* [5], era la millor opció.

Es pot observar a l'apartat d'experiments 7.1 la prova que s'ha dut a terme per a comparar els models.

5.1.3 Tracking i reidentificació

Un cop aconseguida una detecció estàtica satisfactòria, seguidament, s'haurà d'aplicar diferents models per a poder enllaçar aquestes deteccions al llarg del temps.

L'objectiu del seguiment d'objectes múltiples (MOT) és assignar un identificador únic (ID) a cada porc i mantenir-lo inalterat durant tota la seqüència de vídeo de la manera més estable possible. Com es pot veure a la *Figura 4*.




Figura 2: Imatge seguiment porcs amb ID corresponent.

Per dur a terme aquesta tasca, s'han implementat i comparat dos dels algorismes més avançats en l'estat de l'art actual, integrats amb les prediccions del model *YOLOv8*: el *ByteTrack* [15] i el *BoT-SORT* [14] explicats els dos a l'estat del art.

Per tal de poder fer proves amb els diferents models i hiperparàmetres, s'han utilitzat només els models *Small* i *Nano*. Aquesta decisió s'ha pres atès que l'entorn de *Google Colab* [27] que es disposa no permetria fer execucions tan llargues amb el model *Medium*, fet que hauria alentit dràsticament l'evolució del treball.

D'altra banda, s'han executat diverses proves per a avaluar el rendiment dels models de segmentació combinats amb diferents algorismes de seguiment i amb diversos hiperparàmetres (s'han ajustat només els més importants o els que s'ha previst que podrien oferir millors resultats). Aquesta avaluació ha permès determinar quin sistema de seguiment oferia la millor precisió. Es pot veure a l'apartat d'experiments 7.2

5.1.4 Auto encoder

Un cop aconseguit un model prou robust i amb una gran precisió, el següent repte era millorar la reidentificació (Re-ID) dels porcs, ja que tot i tenir un model més precís no s'aconseguia millorar els resultats respecte a la pèrdua d'identitat.

Per solucionar aquest problema, el sistema integra un *Auto-Encoder*, una xarxa neuronal encarregada d'extreure un vector de característiques de cada porc per poder-lo reconèixer més endavant. Entrenar un model específic per reconèixer porcs farà que el nostre model sigui molt més personalitzat i precís. Seguidament es pot veure el funcionament a la *Figura 3*.




Figura 3: Funcionament Auto encoder.

Per fer l'entrenament del model, es requerien imatges de porcs amb el fons blanc per tal d'entrenar la xarxa neuronal perquè sigui capaç d'extreure característiques molt precises de cada individu. Per fer-ho, s'ha utilitzat el model YOLOv8m-seg entrenat anteriorment, modificant la configuració del codi perquè extregui 5.000 imatges com les que es poden veure a la Figura 3, obtingudes de diferents vídeos per millorar al màxim la diversitat de la mostra.



Figura 4:

Siluetes d'un porc retallada per a entrenar l'Auto-Encoder

5.1.5 Assignació d'identitats i Algorisme Hongarès

Per a saber quin ID serà assignat a cada animal de la millor manera possible s'ha hagut de recórrer a l'Algorisme Hongarès, ja que a vegades el percentatge de similitud dels animals era molt proper. Aquest algorisme calcula la semblança entre els vectors, següidament fa el mateix amb els porcs que hi ha a la pantalla i els que té en memòria. Un cop fet això busca la combinació més òptima. D'aquesta manera ens assegurem que un identificador només pot ser assignat a un únic porc en cada fotograma, eliminant els duplicats i els intercanvis erronis d'identitats.

A l'apartat 7.3 dels experiments es pot veure el resultat del algorisme definitiu.

5.2. Dashboard

Per tal d'expressar al màxim la robustesa assolida pel model de seguiment 2D i apropar-lo a l'usuari final, l'objectiu d'aquesta nova fase ha estat traduir les coordenades i els identificadors continus que proporciona el model en mètriques de comportament amb valor real per a la gestió ramadera, presentant-les en una interfície d'usuari clara.

5.2.1 Mètriques

A partir de les dades disponibles, s'ha decidit mesurar les mètriques següents: la distància total recorreguda, el nombre de vegades que els animals accedeixen a la bàscula (zona on també es troba la menjadora), el temps de permanència a l'interior i l'estat del porc (en repòs o en actiu).

Per fer-ho, s'han hagut de tenir en compte els aspectes següents:

- **Distància recorreguda i estat d'activitat:** Es calcula la distància euclidiana entre els centroides de

les caixes delimitadores (*bounding boxes*) en fotogrames consecutius. S'ha aplicat un factor de conversió espacial basat en l'amplada aproximada del corral (1 metre = 266 píxels). Per evitar l'acumulació de falses distàncies, s'ha implementat un filtre de soroll amb un llindar de 7 píxels. Tot desplaçament inferior a aquest valor es descarta, registrant l'animal en estat de "Repòs"; en cas contrari, es classifica com a "Actiu".

- **Interacció amb la menjadora/bàscula:** S'ha definit l'estructura de la bàscula com una Regió d'Interès (ROI) fixa. Mitjançant la intersecció geomètrica entre els centroides dels porcs i aquesta àrea, un mecanisme de control booleà permet comptabilitzar el nombre d'accessos individuals i el temps de permanència exacte de cada animal.

5.2.2 Disseny interfície i resultat

Després d'avaluar diferents opcions, s'ha determinat que la millor manera de presentar les dades de seguiment és mitjançant l'ús d'una pantalla dividida. Aquesta implementació ha donat lloc a un dashboard visual on s'observa simultàniament el vídeo en temps real amb els identificadors numèrics sobre cada animal, acompanyat d'un panell lateral que recull la informació necessària per a cadascun d'ells (estat, distància recorreguda i visites a la menjadora).

Aquest disseny prioritza la claredat i la usabilitat, donant pas a un resultat intuïtiu i molt fàcil d'interpretar per a usuaris finals sense coneixements informàtics previs, com ara veterinaris o el mateix personal de la granja, convertint el model d'intel·ligència artificial en una eina pràctica i accessible, tal com es pot observar a la figura 4.




Figura 5: Resultat dashboard

5.3 DataSpaces amb Federated-Learning

5.3.1 Que són els Dataspace i el Federated-Learning

Durant el desenvolupament d'aquest projecte, s'han patit diversos retards en l'entrega d'alguns conjunts de dades requerits, fet que ha limitat l'abast en certes fases del projecte. Arran d'aquesta problemàtica, s'han investigat mètodes alternatius que permetin optimitzar la compartició i l'ús de dades per a l'entrenament de models

d'Intel·ligència Artificial, evitant la dependència de transferències massives.

Actualment, el desenvolupament de models robusts de visió artificial al sector ramader topa amb la barrera dels *data silos*. Les explotacions generen grans volums d'imatges, però la seva compartició es veu bloquejada pel secret industrial, la privadesa o els elevats costos de transferir terabytes cap a un servidor central. Aquest aïllament penalitza greument la capacitat dels models per generalitzar, ja que l'entrenament amb dades d'una única empresa sol estar limitat a condicions d'il·luminació i perspectives molt específiques.

Com a solució a aquesta barrera, i prenent com a referència les recents iniciatives de la Unió Europea [19] per a la creació d'Espais de Dades amb Aprenentatge Federat sota estàndards internacionals aplicats al sector agrari, en aquest projecte s'ha dissenyat una prova de concepte. En lloc de dependre d'infraestructures industrials complexes, s'ha creat un sistema a petita escala per posar aquesta tecnologia a la pràctica.

Aquest mètode, en lloc de moure les dades cap al model, s'envia el model matemàtic a l'ordinador local de cada granja perquè s'entreni dins del propi servidor, tal com es detalla en l'esquema de la Figura 7.




Figura 6: Esquema representatiu Dataspace

Aquesta manera de funcionar té dos grans avantatges. D'una banda, permet a granges petites o mitjanes col·laborar per aconseguir un model de detecció universal molt més precís, compartint només el que aprèn la xarxa neuronal sense que les seves imatges hagin de sortir mai de les instal·lacions. D'altra banda, ofereix a les grans empreses una eina molt més senzilla per entrenar models utilitzant la informació de totes les seves naus alhora, respectant al 100% la privacitat i la propietat de les dades de cada participant.

5.3.2 Disseny Dataspace conceptual

Per dur a terme aquesta simulació d'espai de dades, s'ha construït un entorn de proves a l'entorn de *Google Drive* utilitzant la llibreria d'aprenentatge federat [26] *Flower* (flwr). S'ha executat als servidors de *Google Colab* per disposar d'alta potència de processament. En aquest cas,

per avaluar el rendiment de l'entrenament, s'han utilitzat els models YOLOv8 en la seva versió *Small*.

Un cop estructurat, l'arquitectura s'ha dividit en dos nodes aïllats (Client 0 per a la Granja Antiga i Client 1 per a la Granja Nova) i un servidor central. Un aspecte fonamental d'aquesta prova és l'ús de la llibreria *Flower* [20] per garantir el funcionament més acurat possible del Dataspace. El motor de *Flower* gestiona els clients de manera asíncrona creant subprocessos independents (assignant PIDs únics) i reservant fraccions de memòria GPU aïllades per a cadascun. D'aquesta manera, tot i executar-se a la mateixa màquina, s'impossibilita tècnicament que el Client 0 pugui accedir a les dades del Client 1, replicant la barrera de privacitat d'un espai de dades real.

El sistema funciona amb cicles anomenats rondes federades. A l'inici de cada ronda, el servidor envia el model global als clients. Aquests realitzen un entrenament local amb les seves imatges. En acabar, no envien cap dada visual cap a l'exterior, sinó que extreuen només els nous paràmetres matemàtics apresos i els retornen al servidor.

Finalment, el servidor central recull aquests paràmetres i hi aplica l'algorisme *Federated Averaging*, calculant la mitjana matemàtica per actualitzar el model global. Aquest cicle es repeteix durant 20 rondes, donant temps suficient a la xarxa neuronal per consolidar el coneixement compartit de totes dues granges.

A l'apartat 7.4 dels experiments es pot veure la prova que s'ha dut a terme per a avaluar el rendiment dels diferents models.

5.4 Processament 3D i predicció del pes

5.4.1 Creació dataset 3D

Per treballar amb les imatges .ply, el primer pas ha estat preparar i netejar les dades.

S'han transformat les imatges de 10 a 8 bits per tal d'estandarditzar els arxius i poder-los processar correctament. A més a més, s'han retallat els núvols de punts en els eixos X, Y i Z per eliminar les zones de la granja que no interessaven, atès que el camp de visió de la càmera és molt ampli. Aquest procés ha permès aïllar els volums dels porcs perfectament, facilitant-ne la detecció posterior, tal com es pot observar a la Figura 6.



Figura 7: Núvol de punts retallat mostrant només l'àrea d'interès

5.4.2 Homografia

Un cop preparats i retallats els núvols de punts, el pas següent és establir una correspondència espacial entre aquest entorn tridimensional i les deteccions 2D generades pel model YOLO. Per a poder-ho fer correctament s'ha hagut de fer una Homografia [21].

Aquest procediment consisteix a extreure les coordenades de quatre punts de referència clars i inamovibles a la imatge 3D (com poden ser les cantonades de la menjadora o marques específiques a terra) i emparellar-los amb els mateixos quatre punts a la imatge 2D.

A partir d'aquests quatre parells de coordenades, l'algorisme calcula la matriu d'homografia. Aquesta matriu actua com un pont matemàtic que tradueix les coordenades d'un pla a l'altre, tal com s'il·lustra a la Figura 7. Cal tenir en compte que, com que actualment no es disposa d'imatges enregistrades en el mateix instant de temps per a totes dues càmeres, no es podrà realitzar una correspondència perfecta amb els porcs en moviment; malgrat això, serà completament suficient per validar com funciona la transformació sobre l'estructura del corral. Finalment, aquesta operació permetrà agafar el polígon exacte del porc detectat en el vídeo i projectar-lo sobre el núvol de punts 3D.




Figura 8: Resultat de prova homografia

Per fer l'homografia de prova que es mostra a la Figura 7, s'ha utilitzat la imatge 3D sense retallar l'eix Z per tal de mantenir la referència del terra i apreciar el resultat d'una manera més il·lustrativa. D'altra banda, s'ha projectat un quadrat verd a la imatge 2D inicial per poder avaluar visualment i de manera clara l'efecte de la transformació geomètrica sobre l'espai tridimensional.

5.4.3 Integració 2D i 3D

Un cop feta l'homografia, el darrer pas del procés consisteix a connectar el món 2D i el 3D per a poder conèixer el pes de cada porc per separat. Per fer-ho, s'haurà d'aïllar la silueta exacta en 3D de l'animal a partir del seguiment que es fa en 2D. Seguidament, es disposa d'un fitxer *Excel* facilitat per l'IRTA on es registren els pesos exactes de cada animal en el moment en què accedeix a la bàscula. Gràcies a la correspondència entre la càmera bidimensional, la tridimensional i les dades esmentades anteriorment, es podrà entrenar un model capaç de predir el pes del porc a partir del seu volum.

Actualment, com s'ha explicat anteriorment, la implementació d'aquesta fase no es viable. Les imatges 3D

rebudes per l'IRTA, requereixen una marca temporal per a poder fer la correspondència 2D i 3D correctament. Tot i així, s'ha deixat preparat tot el codi necessari per a poder, reprendre el projecte de la predicció dels pesos, quan es rebin totes les dades necessàries del IRTA.

6 EXPERIMENTS

6.1 Comparació rendiment models segmentació

Per tal de comparar el rendiment de detecció dels diferents models s'han provat aquestes tres variants, de menys a més complexitat: YOLOv8 Nano, YOLOv8 Small, YOLOv8 Medium (yolov8m-seg).

Els tres models s'han entrenat de forma idèntica durant 50 èpoques (epochs) amb una resolució d'imatge de 640 píxels. Per avaluar el rendiment de cada arquitectura sobre el conjunt d'imatges de validació, s'ha utilitzat la mètrica estàndard mAP50 (Mean Average Precision amb un llinar d'Intersecció sobre Unió del 50%) i la més estricta mAP50-95. A la Taula 1 es mostren els resultats quantitatius obtinguts en aquest primer experiment de prova de concepte:

Model	T. train	mAP50 (Màscara)	mAP50-95
YOLOv8 Nano	3.92	95.18	76.79
YOLOv8 Small	4.37	95.50	80.20
YOLOv8 Medium	8.07	96.06	80.20

Taula 1: resultats rendiment dels 3 models

L'anàlisi d'aquestes dades mostra que l'arquitectura Small presenta un millor rendiment general respecte al model Nano, mentre que l'arquitectura Medium pràcticament duplica el temps d'entrenament sense aportar una millora significativa de precisió en aquest entorn inicial tan reduït.

Tot i aquests resultats amb el *dataset* inicial, de cara a la fase de *tracking* que s'explicarà en l'apartat següent, la capacitat d'extracció de característiques del model esdevé molt important. Ja que les imatges definitives de la granja presenten situacions molt complexes per al seguiment, amb constants canvis de llum i severes oclusions entre els animals, s'ha determinat que cal agafar el model més potent, prioritzant la màxima robustesa tot i ser menys lleuger. Per aquest motiu s'ha entrenat exclusivament el model YOLOv8 Medium amb el *dataset* definitiu de les noves instal·lacions, assegurant així la millor base possible per al repte de la reidentificació. A més a més, s'ha entrenat amb 220 imatges, ja que aquest model requereix més informació per a no caure en l'*overfitting*.

Els resultats d'aquest model han estat molt bons. S'ha aconseguit una precisió (segons la mètrica mAP50) de 0.995 sobre el *dataset* de validació. Això vol dir que el polígon que dibuixa el sistema s'ajusta pràcticament a la perfecció a la silueta real de l'animal.

6.2 Comparació algorismes de seguiment

L'experiment següent analitza les diferents combinacions dels models YOLO *Nano* i *Small* amb els algorismes de seguiment BoT-SORT i ByteTrack, per a diferents valors de memòria en fotogrames. Com a mètrica d'avaluació, s'ha utilitzat el nombre d'IDs únics que detecta cada model en un vídeo d'1,5 minuts. Aquest vídeo conté escenes amb força oclusions i moviment, sent 10 la quantitat real de porcs dins del recinte. Per tant, un resultat geomètric de 10 IDs indica que no hi ha hagut cap pèrdua ni duplicació d'identitat durant el seguiment. A la *Taula 2* es poden observar els tres millors resultats obtinguts en aquestes proves.

Model	Tracker	Memòria	IDs
YOLOv8 Nano	BoT-SORT	120	10
YOLOv8 Nano	ByteTrack	120	11
YOLOv8 Small	ByteTrack	120	18

Taula 2. Configuracions òptimes després de l'estudi d'optimització.

Com es pot observar, l'aplicació d'un llinard de confiança del 90% i un buffer de memòria de 120 fotogrames ha estat clau per a obtenir bons resultats, ja que d'aquesta manera el sistema no perd la referència de cada animal tan ràpidament davant d'occlusions temporals. D'altra banda, es confirma que BoT-SORT ha demostrat ser l'algorisme de seguiment més eficient per a aquest escenari; la seva major complexitat permet obtenir resultats superiors, motiu pel qual s'ha seleccionat com a base per a les fases posteriors.

Tal com s'ha esmentat anteriorment, no s'han pogut realitzar les proves de rendiment amb el model YOLO *Medium* a causa dels elevats temps d'execució en l'entorn de proves. Tot i això, aquest model de detecció més potent és el que s'ha utilitzat finalment per analitzar les imatges definitives. Malgrat els bons resultats s'ha continuat investigant mètodes addicionals de seguiment. En situacions complexes (com ara a les zones d'alimentació o pesatge), continuaven produint-se intercanvis d'identitat (ID switches) i errors de continuïtat, els quals es poden observar detalladament a l'Apèndix A2.

6.3 Resultats model definitiu de tracking

Un cop implementades totes les millores, s'ha provat el sistema amb un vídeo que no s'havia utilitzat per entrenar el model. Aquest era un dels vídeos més complexos de processar, ja que presentava un alt grau de moviment. Un cop processat, el sistema ha detectat un total de 12 identificadors enfront dels 11 porcs reals que hi havia a la granja. A la *Figura 4* es mostra un fotograma del funcionament correcte del model. A més a més, al final de l'apèndix A2 es pot veure l'anàlisi de l'error produït en aquest vídeo.




Figura 9: Fotograma del video de validació

En conclusió, l'elecció d'un model *Medium* més robust i el disseny d'un *Auto-Encoder* especialitzat han resolt els problemes d'intercanvi d'identitats i el soroll de fons del model inicial. El sistema actual és estable i està totalment preparat per afrontar la següent fase del projecte: l'estimació del pes mitjançant la visió 3D.

6.4 Comparació models estàndards respecte model Data Spaces

Per a calcular els resultats d'aquest model respecte els anteriors, per a poder veure els avantatges que té els dataspaces hem validat el nou model, el model creat per a la granja antiga i el model creat per a la granja nova amb imatges de les dues granges, de manera que, com es veu a la *Taula 4*, es mostrin les avantatges i desavantatges de cada un.

Model Avaluat	Precisió Granja Antiga	Precisió Granja Nova
Model Granja antiga	94,52%	33,25%
Model granja nova	61,70%	99,42%
Model Federat	93,18%	98,50%

Taula 3: Taula precisió model antic, nou i federat

Els resultats de la *Taula 4* mostren una clara limitació en els models locals: tot i assolir precisions òptimes al seu propi entorn, pateixen un fort sobre-ajustament (*overfitting*) i el seu rendiment cau dràsticament a la instal·lació contrària a causa de diferències visuals com la il·luminació o la genètica dels porcs. Per contra, el model federat supera aquesta barrera i generalitza amb èxit a totes dues granges (93,18% i 98,50%). Aquestes dades demostren que la compartició de paràmetres permet obtenir un model global robust i estable, aconseguint un alt rendiment, fins i tot, emprant una arquitectura més lleugera (YOLOv8 *Small*).

7 CONCLUSIONS

D'aquest projecte se'n poden extreure diverses conclusions. Algunes han seguit la planificació inicial i d'altres han anat sorgint arran de reptes tècnics i limitacions amb el conjunt de dades proporcionat per l'IRTA. A continuació, s'estructuren les conclusions dividint-les en el grau d'assoliment dels objectius inicials, les solucions

desenvolupades a posteriori i, finalment, les possibles línies de treball futur.

7.1 Conclusions Objectius Inicials

D'una banda, pel que fa als objectius proposats en l'àmbit de la visió 2D, s'han obtingut uns resultats excel·lents. S'han entrenat diversos models de xarxes neuronals convolucionals YOLO fins a trobar els paràmetres i condicions òptimes amb l'arquitectura YOLOv8 *Medium*, la qual ha assolit una precisió mAP50 d'un 99,5% sobre les dades de validació. A més a més, s'ha integrat un *Auto-Encoder* entrenat exclusivament amb imatges de porcs per assolir el millor seguiment i re-identificació possible, juntament amb l'Algorisme Hongarès. Aquesta combinació ha permès que, tot i la complexitat de diferenciar els individus, el sistema s'hagi pogut provar amb èxit en vídeos complexos (amb diferents condicions de llum i oclusions), detectant només 12 identificadors per a un grup d'11 animals reals. A part, s'ha desenvolupat un *dashboard* capaç de calcular mètriques clau com la distància recorreguda, l'estat de l'animal (repòs o moviment) i les visites a la menjadora.

Tot i que el model pot seguir evolucionant, aquests resultats demostren que és completament viable crear una tecnologia de baix cost, lleugera i escalable que permetria, si es desenvolupés a escala industrial, controlar grans quantitats de bestiar per millorar tant el benestar animal com el rendiment de la granja.

D'altra banda, pel que fa a la integració 3D al projecte, s'ha assolit de manera parcial. S'ha desenvolupat la part de tractament de les dades ply, retallant els eixos X, Y i Z per deixar el màxim al descobert les àrees d'interès, és a dir, la silueta dels porcs. A més a més, s'ha desenvolupat el codi que calcula la matriu d'homografia planar entre la imatge 2D i la 3D per poder relacionar ambdues perspectives, ja que això en un futur servirà per ubicar la posició exacta de cada animal, calcular-ne el volum i, conseqüentment, el pes.

Tanmateix, no s'ha pogut continuar avançant en el desenvolupament d'aquest apartat per la manca de dades i de les metadades necessàries en cada captura tridimensional que permetessin correlacionar-les. Tot i això, s'ha deixat preparada tota la infraestructura possible per tal que, en un futur, es pugui reprendre fàcilment la implementació d'aquest apartat.

7.2 Desenvolupaments posteriors

Arran de les limitacions sorgides en el desenvolupament 3D, es va decidir explorar noves vies d'investigació per donar continuïtat al treball. Així, es va introduir el concepte d'Espais de Dades (*Data Spaces*) combinat amb l'Aprenentatge Federat (*Federated Learning*). Aquest enfocament permetria que projectes futurs d'aquesta mateix tipus es poguessin implementar i entrenar evitant els

bloquejos per falta de dades.

Tal com s'ha explicat en apartats anteriors, s'ha creat una representació a petita escala d'un espai de dades, utilitzant les imatges de dues granges diferents. El model federat resultant, tot i basar-se en una arquitectura YOLO més petita que els models entrenats per les granges individuals, ha donat uns resultats excel·lents sobre el conjunt d'imatges de validació d'ambdues instal·lacions, amb una precisió del 93,18% a la Granja Antiga i del 98,50% a la Granja Nova. Per contra, en provar els models entrenats individualment a cada granja amb les imatges de la instal·lació contrària, el rendiment ha estat molt inferior, patint una caiguda fins al 33,25% de precisió. Cal destacar que aquest entrenament col·laboratiu s'ha dut a terme sense que cap de les granges, ni tampoc el desenvolupador, pogués veure o accedir a les imatges de l'altra.

D'aquesta manera, es conclou que, mitjançant un model de col·laboració descentralitzada com aquest, es poden assolir eines d'intel·ligència artificial molt robustes. Això és possible gràcies a l'aprenentatge de les xarxes neuronals en situacions i amb individus molt diferents, evitant el sobreajustament i sense comprometre en cap moment la privacitat de les dades.

7.3 Treball futur

A continuació, es detallen diverses línies de continuació per a l'evolució d'aquest projecte:

1. **Estimació del pes:** Un cop s'obtinguin les dades sincronitzades de l'IRTA, es proposa reprendre el desenvolupament tridimensional. Mitjançant l'homografia validada, es podrien aïllar els punts del núvol que conformen l'animal, calcular-ne el volum (per exemple, utilitzant un algorisme de *Convex Hull*) i entrenar un model de *Deep Learning* capaç de predir el pes real utilitzant els registres de la bàscula com a dades d'entrenament.
2. **Desplegament en un entorn en directe:** Implementar el sistema en un dispositiu local a una granja o al núvol per a poder executar el model en temps real, processant els fotogrames a mesura que es capturen per oferir als veterinaris i ramaders mètriques instantànies de cada animal.
3. **Millora de mètriques i dashboard:** Un cop integrats els models 2D i 3D, caldria col·laborar novament amb els experts per definir quines són les mètriques clíniques més rellevants per avaluar l'estat dels porcs. L'objectiu seria desenvolupar una aplicació o un *dashboard* independent i més complet que permetés un seguiment sanitari molt més exhaustiu i fàcil d'interpretar per als professionals.

7.4 Conclusió final

Després de tot el treball dut a terme durant aquests mesos, es pot confirmar que aplicar la intel·ligència artificial a la ramaderia és totalment viable, sense la necessitat de grans infraestructures per obtenir uns resultats molt satisfactoris. A més a més, els problemes sorgits durant el desenvolupament del projecte han permès investigar els Espais de Dades (*Data Spaces*), els quals, en un futur no tan llunyà, podrien esdevenir una peça clau per implementar models d'intel·ligència artificial avançada en empreses o granges de petites dimensions, sense la necessitat de dependre d'una gran quantitat de dades o de mostres altament variades i evitant compartir imatges o dades privades.

Aquesta eina creada podria contribuir a democratitzar la tecnologia, ajudant els ramaders més petits a ser competitiu, garantint el benestar animal i evitant la desaparició d'un sector i d'un ofici tradicional tan valuosos.

ÚS DE LA IA GENERATIVA

Per a la redacció d'aquest informe inicial s'ha fet ús de *Google Gemini* [4], una eina basada en IA generativa amb l'únic propòsit de millorar l'expressió escrita i avaluar diferents opcions de disseny tècnic.

En l'àmbit del desenvolupament de software, la IA s'ha emprat exclusivament com un assistent tècnic per depurar errors (*debugging*), optimitzar la sintaxi i aportar idees en el disseny dels experiments. Aquest ús s'ha fet sota un criteri estrictament ètic, garantint sempre que la lògica algorítmica i l'autoria del codi recauen íntegrament en l'alumne.

Tot i que ha servit com a suport per reformular textos i analitzar possibles enfocaments metodològics, la direcció del projecte, el contingut i les decisions finals adoptades en aquest document s'han establert de manera completament autònoma i manual.

BIBLIOGRAFIA

- [1] IRTA, "Centre de Control i Avaluació de Porcí," Institut de Recerca i Tecnologia Agroalimentàries. [En línia].
- [2] Ministerio de Agricultura, Pesca y Alimentación (MAPA), "Indicadores económicos del sector de la carne de cerdo en cifras 2024," 2024. [En línia].
- [3] Trello, "Eina de gestió de projectes i tasques," Atlassian. [En línia].
- [4] Google, "Gemini: Intel·ligència Artificial Generativa," 2024. [En línia].
- [5] Ultralytics, "Ultralytics Docs: YOLOv8 and Vision AI documentation," 2024. [En línia].

- [6] GitHub, "Plataforma de desenvolupament col·laboratiu i control de versions," 2026. [En línia].
- [7] K. He, G. Gkioxari, P. Dollár i R. Girshick, "Mask R-CNN", *Proceedings of the IEEE international conference on computer vision*, pp. 2961-2969, 2017. [En línia].
- [8] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu i A. C. Berg, "SSD: Single shot multibox detector", *European conference on computer vision (ECCV)*, pp. 21-37, 2016. [En línia].
- [9] H. W. Kuhn, "The Hungarian method for the assignment problem", *Naval research logistics quarterly*, vol. 2, núm. 1-2, pp. 83-97, 1955. [En línia].
- [10] M. A. Kramer, "Nonlinear principal component analysis using autoassociative neural networks", *AIChE journal*, vol. 37, núm. 2, pp. 233-243, 1991. [En línia].
- [11] M. Ye, J. Shen, G. Lin, T. Xiang, L. Shao i S. C. Hoi, "Deep learning for person re-identification: A review and outlook", *IEEE transactions on pattern analysis and machine intelligence*, 2021. [En línia].
- [12] A. Bewley, Z. Ge, L. Ott, F. Ramos i B. Upcroft, "Simple online and realtime tracking", 2016 IEEE international conference on image processing (ICIP), 2016. [En línia].
- [13] N. Wojke, A. Bewley i D. Paulus, "Simple online and realtime tracking with a deep association metric", 2017 IEEE international conference on image processing (ICIP), 2017. [En línia].
- [14] N. Aharon, R. Orfaig i B. Z. Bobrovsky, "BoT-SORT: Robust associations multi-object tracking", *arXiv preprint arXiv:2206.14651*, 2022. [En línia].
- [15] Y. Zhang et al., "ByteTrack: Multi-Object Tracking by Associating Every Detection Box", *European Conference on Computer Vision (ECCV)*, 2022. [En línia].
- [16] G. Bradski, "The OpenCV Library", *Dr. Dobb's Journal of Software Tools*, 2000. [En línia].
- [17] OpenCV, "Computer Vision Annotation Tool (CVAT)", 2024. [En línia].
- [18] Meta AI, "Segment Anything Model 3 (SAM 3)", 2025. [En línia].
- [19] Comissió Europea, "European Data Spaces - Shaping Europe's digital future", 2024. [En línia].
- [20] D. J. Beutel et al., "Flower: A Friendly Federated Learning Research Framework", *arXiv preprint arXiv:2007.14390*, 2020. [En línia].
- [21] G. E. Hinton i R. R. Salakhutdinov, "Reducing the dimensionality of data with neural networks", *Science*, vol. 313, núm. 5786, pp. 504-507, 2006. [En línia].
- [22] Y. Zhao et al., "Federated learning with non-iid data", *arXiv preprint arXiv:1806.00582*, 2018. [En línia].
- [23] Google, "Google Colaboratory: Entorn de desenvolupament interactiu de Python basat en el núvol", 2024. [En línia].

APÈNDIX

A1. DIAGRAMA DE GANTT

En aquest apèndix s'inclou el diagrama de Gantt complet corresponent a la planificació i distribució temporal de les tasques del projecte. Com es pot veure en la *Figura A1.1*




Figura A1.1: Oclusió del porc amb la paret i canvi de tonalitat a causa de la il·luminació

A2. LIMITACIONS EN EL MODEL BASE

Per tal d'entrenar un model més robust, es va procedir a analitzar els resultats empírics de l'algorisme en diversos vídeos. Es va posar el focus en els moments més crítics: aquells on es perdia la identitat dels animals o on es generaven canvis d'ID sense justificació aparent.

En la primera granja hem trobat aquests errors del model:

- Disposició de la càmera i il·luminació:** Com s'observa a les *figures A2.1 i A2.2*, tant la perspectiva de la càmera com la incidència directa de la llum solar afecten negativament el rendiment del model. Aquests factors generen pèrdues d'identitat per oclusió amb la paret i la creació de noves identitats a causa dels canvis de color a la pell del porc provocats pel sol. En el nou conjunt de dades, que es detallarà més endavant, es demostrarà l'efecte de comptar amb una càmera disposada òptimament.



Figura A2.1: Oclusió del porc amb la paret i canvi de tonalitat a causa de la il·luminació




Figura A2.2:
Identificació anòmala provocada per l'oclusió i la incidència solar

- **Oclusions i solapament (Overlapping):** El comportament natural dels porcs, que tendeixen a descansar amuntegats, provocava que les caixes delimitadores (*bounding boxes*) englobessin parts de múltiples individus. Això generava fusions d'identitat temporals i l'aparició de falsos identificadors nous. A més, en situacions d'amuntegament extrem, el sistema aïllava fraccions molt petites del cos de l'animal, fent impossible per a l'extractor de característiques relacionar aquest fragment amb l'individu complet real, creant de nou IDs erronis. Aquest efecte és observable a la *figura A2.3*.



Figura A2.3: Generació d'un nou individu a causa de la falta d'informació per oclusió

- **Intercanvis d'identitat:** En situacions de creuament ràpid entre dos animals, la pèrdua de tracking espacial provocava una fallada en el buffer de memòria, forçant l'algorisme a reassignar identificadors nous, generalment de manera errònia.
- **L'efecte deformador de la bàscula:** Es va detectar que elements estructurals, com els barrots metàl·lics de la menjadora, tallaven la silueta visual de l'animal. Quan el model intentava extreure característiques d'un porc parcialment tapat pels ferros, guardava una representació corrupta de l'individu. Fins i tot, en moltes situacions, el model reconeixia l'animal com si fossin diversos individus diferents, ja que des de la perspectiva superior la silueta es veia fragmentada, tal com s'il·lustra a la *figura A2.4*.



Figura A2.4: Identificació de diversos individus per culpa de la bàscula

En les imatges de la segona granja hem trobat només aquest error del model:

Seguidament, s'ha analitzat exactament en quin punt es produeix l'error d'identificació detectat. A la *figura A2.5* es pot observar el fotograma on es perd la identitat del porc que es trobava dins la menjadora. Com que l'animal estava dins d'aquesta estructura des de l'inici del vídeo, el sistema va memoritzar la seva silueta deformada pels barrots de ferro. En sortir-ne, el canvi visual va ser tan bruscat que l'algorisme no el va reconèixer i va crear un ID nou per equivocació.



Figura A2.5: Moment de l'error d'identificació en sortir de la bàscula