

Detecció de Comportament i Estimació de Pes de Porcs amb Visió 2D i 3D

Pere Llauradó Adeva

1 INTRODUCCIÓ

El meu avi, que va ser pastor i ramader de xais des dels 6 anys, podia dir per experiència si un animal estava malalt, estressat o tenia problemes de creixement a ull nu, sense cap mena de tecnologia. Actualment, se sacrifiquen més de 52 milions de porcs només a l'Estat espanyol, i la població porcina ha augmentat més d'un 133% en els últims 28 anys [3]. Davant d'aquest augment desmesurat, és molt important garantir el benestar de cada animal durant la seva estada a la granja; però, avui dia, som incapaços de vigilar i garantir aquest benestar a simple vista.

Al mateix temps, a la carnisseria de la meva mare puc presenciar la pressió que rep aquest sector. El preu del porc no ha parat d'augmentar, sent un dels productes que més ha impulsat la inflació alimentària i arribant a registrar increments interanuals d'un 13,6% segons l'IPC [3]. A més, el consumidor exigeix cada cop una producció més ètica i amb certes certificacions que garanteixin el benestar animal [4]. Amb uns costos de producció tan disparats, els marges de benefici tant de carnisseres com de grangers s'estan reduint de manera preocupant. Com es pot assegurar una vida digna als animals sense ofegar econòmicament els ramaders?

Aquest TFG proposa crear un "pastor digital" mitjançant tècniques d'Intel·ligència Artificial i Visió per Computador (utilitzant dades 2D i 3D de l'IRTA [1] i el CVC [2]) per monitorar de forma autònoma el comportament, la salut i el pes dels porcs. Així, la tecnologia esdevé una solució pràctica i no invasiva per garantir el benestar animal i, alhora, millorar la rendibilitat econòmica de les granges. L'objectiu d'aquest informe inicial és, doncs, establir-ne les bases tècniques i metodològiques.

2 CONTEXTUALITZACIÓ

Aquest Treball de Final de Grau se centra en el disseny i desenvolupament d'un sistema basat en Visió per Computador i Deep Learning per a l'anàlisi automatitzat del comportament i l'estimació de pes de porcs en entorns reals de granja. Mitjançant l'ús combinat d'imatges 2D i dades volumètriques 3D, capturades en col·laboració amb l'IRTA [1] i el Centre de Visió per Computador de la UAB [2], el projecte busca proporcionar eines tecnològiques avançades per a la gestió ramadera.

Actualment, el monitoratge a les explotacions es realitza en gran mesura de manera manual, la qual cosa resulta costosa i limitada en el temps. Aquest projecte neix amb la voluntat de solucionar aquesta mancança i es fonamenta en tres pilars de motivació principals:

- **Millora del benestar animal:** La implementació d'aquesta eina permetrà tenir informació constant (24 hores al dia, 7 dies a la setmana) sobre el comportament, l'evolució del pes, l'estat de salut, etc. Això s'aconsegueix de manera contínua, no invasiva i sense la necessitat de tenir un operari present constantment.
- **Optimització del rendiment i benefici ramader:** L'automatització d'aquest monitoratge permetrà als ramaders tenir els animals molt més vigilats i atesos, anticipant-se a possibles malalties o problemes de creixement. Alhora, aquesta eficiència redueix la dependència de mà d'obra intensiva per a tasques d'observació, millorant així l'escalabilitat i els marges de benefici de les granges.
- **Motivació personal i vincle familiar:** Més enllà del repte tècnic que suposa la intel·ligència artificial, aquest projecte té una forta component personal. Els meus orígens familiars estan estretament lligats al sector: el meu avi va ser pastor i granger de xais, la família del meu pare tenia porcs, i la meva mare regenta una carnisseria. Aquest bagatge i connexió amb el món rural i la indústria càrnica em generen una il·lusió i una motivació especials per aplicar els meus coneixements d'enginyeria per aportar valor a un sector tan proper a mi.

3 OBJECTIUS

L'objectiu principal d'aquest Treball de Final de Grau és dissenyar, desenvolupar i avaluar un sistema basat en Visió per Computador i models de Deep Learning per automatitzar el monitoratge del comportament, prevenció de malalties i l'estimació de pes de porcs en entorns de granja, usant càmeres 2D i 3D.

Per assolir aquesta fita, l'abast del projecte es desglossa en els següents objectius específics:

- **Definició de requeriments i mètriques clíniques:** Analitzar les necessitats reals de gestió ramadera i benestar animal mitjançant entrevistes i col·laboració directa amb professionals del sector (veterinaris

porcins), per tal de definir quins comportaments, malalties i marges d'error en el pes són crítics a monitorar o més imprescindibles per a fer més pràctic el nostre sistema.

- **Tractament de dades:** Processar, estructurar i etiquetar un dataset d'imatges 2D i dades volumètriques 3D, capturat i proporcionat en una granja experimental en col·laboració amb l'IRTA [1] i el Centre de Visió per Computador [2] (CVC) de la UAB.
- **Desenvolupament de models de segmentació:** Entrenar i implementar models de Deep Learning capaços de segmentar i identificar de manera individualitzada cada porc dins dels corral·ls a partir de les imatges capturades i detectar quin de tots té un millor rendiment.
- **Anàlisi de comportament i estimació de pes:** Desenvolupar els algorismes necessaris de deep learning per classificar els patrons de moviment/comportament detectats i dissenyar un mètode precís per calcular el pes dels animals aprofitant les dades espacials (3D).
- **Avaluació i comparativa tècnica:** Comparar diferents tipus d'algorismes com la llibreria YOLO [7], algorismes CNN i altres tècniques clàssiques de VC. Per veure quin dona millor rendiment i més òptim.

Per a l'organització d'aquest TFG s'ha optat per una adaptació de la metodologia àgil (Agile), ajustada a les necessitats d'un únic desenvolupador. El treball s'estructurarà Sprints de 5 setmanes, corresponent-se cada un amb les entregues corresponents. S'ha optat a iteracions més llargues del que és habitual, ja que els models de Deep Learning a entrenar i les dades a processar requeriran llargs temps d'execució, d'aquesta manera es podrà realitzar entregables al final de cada Sprint molt més complets.

Per a la planificació i el seguiment diari de les tasques, es farà ús d'un tauler Kanban mitjançant la plataforma Trello [5]. S'ha prioritzat aquesta eina ja que permet organitzar el projecte de manera molt visual, senzilla i amb moltes opcions d'edició diferents. A més, independentment de la gestió de tasques, tot el control de versions del codi, l'històric d'entrenaments i els experiments amb els models d'intel·ligència artificial es gestionaran de manera centralitzada mitjançant GitHub [8].

El desenvolupament del TFG consta de 20 setmanes i 4 entregues diferents, amb una càrrega de treball aproximada de 300 hores. S'han alineat els diferents sprints i objectius amb les fites d'avaluació. Com s'ha explicat anteriorment,

cada sprint té una durada exacta de 5 setmanes.

Sprint 1: Fonamentació i Planificació (Febrer - Març)

Aquest primer cicle (actualment finalitzat) ha correspost a la fase introductòria i "filosofal" del projecte. S'ha dedicat a entendre el problema, establir l'abast tècnic i clínic amb el veterinari, preparar les eines de gestió (Trello, repositoris) i estructurar documentalment el treball. Aquesta fase conclou amb el lliurament de l'Informe Inicial (Setmana 4).

Sprint 2: Inici Tècnic i Visió 2D (Març - Abril)

Inici del desenvolupament pràctic, on s'acaben de definir els requeriments més específics amb els veterinaris. Abasta des de la recepció, neteja i etiquetatge de les imatges, fins a l'inici de l'entrenament dels primers models 2D com són CNN i YOLO [7] per detectar les siluetes dels porcs i els comportaments més bàsics. Finalitza amb el lliurament de l'Informe de Progrés I (Setmana 10).

Sprint 3: Integració 3D i Comportament (Abril - Maig)

Aquesta iteració es focalitza a afegir la profunditat espacial. S'incorporen els mapes de profunditat (3D) per desenvolupar els algorismes d'estimació de pes i es programa la lògica per classificar les postures i anomalies de comportament. La fita d'aquest cicle és el lliurament de l'Informe de Progrés II (Setmana 14).

Sprint 4: Avaluació i Tancament (Maig - Juny)

L'últim esprint es destina exclusivament a l'anàlisi de resultats (comparant l'error entre els diferents models i la fusió 2D+3D), al desenvolupament d'una interfície senzilla per avisar els veterinaris i grangers, a l'optimització del codi i a la redacció de la memòria completa. Per a aquesta darrera etapa, les fites oficials són: Proposta Informe Final (Set. 17), Proposta Presentació (Set. 19), Lliurament Final (abans del 29 de juny) i Defensa Pública (del 3 al 8 de juliol).

A continuació, a la *Figura 1*, es mostra el diagrama de Gantt de la planificació. El gràfic permet veure ràpidament com es distribueix la càrrega de treball al llarg de les 20 setmanes i com cada esprint quadra amb les fites de la universitat.




Figura 1: diagrama de Gantt

6 SEGUIMENT DE LA PLANIFICACIÓ

El desenvolupament del Treball de Final de Grau segueix de prop la planificació establerta al diagrama de Gantt presentat en l'Informe Inicial.

6.1 Fase 1

Pel que fa al nivell de seguiment, s'han assolit amb èxit tots els objectius tècnics previstos per a aquesta etapa: s'ha implementat el flux de processament de dades, s'han entrenat els models de segmentació i s'ha optimitzat el sistema de seguiment múltiple (Multi-Object Tracking).

L'únic ajust rellevant respecte a la previsió inicial ha estat derivat del lleuger retard en l'obtenció de les dades definitives per part de la granja experimental de l'IRTA. Lluny de suposar un bloqueig, aquest temps s'ha invertit de manera proactiva en realitzar l'estudi avançat d'hiperparàmetres detallat en l'apartat anterior utilitzant imatges d'arxiu. Aquesta decisió estratègica ha permès construir una base de codi (pipeline) completament automatitzada i depurada.

En conseqüència, no es considera necessari introduir cap modificació estructural en el calendari ni en els objectius globals del TFG. Un cop es rebin els vídeos i mapes de profunditat actualitzats de l'IRTA, el reentrenament del model serà immediat gràcies a la infraestructura ja programada, permetent iniciar l'Sprint 3 (Integració 3D i Comportament) dins dels terminis acadèmics establerts.

7 DESENVOLUPAMENT

A continuació, es detallen els procediments duts a terme per assolir amb èxit els objectius establerts a l'apartat 5. Aquest capítol recull tota l'evolució tècnica del projecte de forma cronològica: des del processament inicial de les dades 2D, l'entrenament dels models de segmentació i seguiment, fins a la implementació de la solució definitiva per resoldre el seguiment temporal i l'estimació del pes dels animals en temps real.

7.1 Preparació de les dades d'entrenament

En primer lloc, s'han obtingut els vídeos dels animals del

2021, enregistrats en un corral amb 10 porcs. A partir d'un script en Python i de la llibreria OpenCV [23], s'han processat els 4 vídeos i se n'han extret automàticament fotogrames cada 25 segons. L'objectiu d'aquest mostreig temporal és crear un *dataset* amb imatges el més diverses possible, per a evitar la semblança entre elles i, per tant, el subajustament (*underfitting*) en certes situacions i el sobreajustament (*overfitting*) en altres. S'han extret exactament 100 imatges, tal com es mostra a la Figura 2.



Figura 1: Fotograma extret sense tractar.

Seguidament, s'ha procedit a l'etiquetatge manual utilitzant l'aplicació web CVAT [24]. Aquesta eina s'ha combinat amb el model SAM 3 [25] (Segment Anything Model 3), la IA de Meta enfocada en la segmentació d'imatges i vídeos. Aquesta integració ha permès crear etiquetes per a cada porc, marcant la posició exacta de cadascun de manera molt precisa per a generar les màscares de cada fotograma que formen la base de dades d'entrenament (Figura 3). En total, s'han preparat 86 imatges d'entrenament i validació, un volum suficient per a dur a terme una prova de concepte inicial amb l'arquitectura YOLOv8.



Figura 3: Imatge processada per SAM a la interfície CVAT.

7.2 Entrenament dels models de segmentació

Un cop preparat i etiquetat el conjunt de dades, s'ha procedit a l'entrenament dels models. Després d'investigar totes les possibilitats per a crear un model basat en xarxes neuronals convolucionals (CNN), s'ha vist que pel volum de dades que tenim, per a un millor rendiment i per a uns resultats ràpids i amb un bon *accuracy* YOLOv8 era la millor opció.

Per tal de trobar l'equilibri òptim entre cost computacional i precisió geomètrica, s'ha plantejat un experiment comparatiu entrenant tres variants d'aquesta arquitectura:

- YOLOv8 Nano (yolov8n-seg): El model més

lleuger i ràpid.

- YOLOv8 Small (yolov8s-seg): Un model amb una xarxa neuronal més profunda i major nombre de paràmetres.
- YOLOv8 Medium (yolov8m-seg): Un model de complexitat superior als anteriors per a comprovar si realment hi ha risc d'*overfitting* amb la base de dades que disposem actualment.

Els tres models s'han entrenat de forma idèntica durant 50 èpoques (epochs) amb una resolució d'imatge de 640 píxels. Per avaluar el rendiment de cada arquitectura sobre el conjunt d'imatges de validació, s'ha utilitzat la mètrica estàndard mAP50 (Mean Average Precision amb un llindar d'Intersecció sobre Unió del 50%).

A la Taula 1 es mostren els resultats quantitatius obtinguts en aquest primer experiment de prova de concepte:

Model	T. train	mAP50 (Màscara)	mAP50-95
YOLOv8 Nano	3.92	95.18	76.79
YOLOv8 Small	4.37	95.50	80.20
YOLOv8 Medium	8.07	96.06	80.20

Taula 1 resultats rendiment dels 3 models

L'anàlisi d'aquestes dades mostra que l'arquitectura Small presenta un millor rendiment respecte el model Nano. Tot i que en el llindar base (mAP50) la diferència és subtil (d'un 0,32% en la segmentació), la millora es fa especialment evident en la mètrica mAP50-95, on el model Small supera el Nano en un 3,41% (80,20 % vs. 76,79 %). Aquest increment demostra que la major complexitat de la xarxa Small permet detectar les siluetes dels porcs amb molta més precisió.

D'altra banda, en observar els resultats del model Medium, es confirma la hipòtesi inicial: el temps d'entrenament pràcticament es duplica (passant de 4,37 a 8,07 minuts), però la precisió estricta (mAP50-95) es manté idèntica en un 80,20%. Aquests resultats ens mostren que afegir més paràmetres a la xarxa no aporta cap benefici real, ja que augmenta pràcticament el doble el temps d'execució i la precisió es manté.

Tenir una bona *accuracy* en *frames* estàtics és molt important, ja que repercuteix directament en el rendiment dels algorismes de tracking. Aquests resultats són suficientment satisfactoris per a poder continuar amb la fase de seguiment temporal amb els models Nano i Small. No s'usarà el model Medium ja que com veiem no té una millora de rendiment real respecte els altres en aquest cas.

7.3 Implementació dels algorismes de seguiment

Un cop aconseguida una detecció estàtica satisfactòria, seguidament, haurem d'aplicar diferents models per a poder enllaçar aquestes deteccions al llarg del temps.

L'objectiu del seguiment d'objectes múltiples (Multi-Object Tracking, MOT) és assignar un identificador únic (ID) a cada porc i mantenir-lo inalterat durant tota la seqüència de vídeo de la manera més estable possible. Com es pot veure a la Figura 4.




Figura 4: Imatge seguiment porcs amb ID corresponent.

Per dur a terme aquesta tasca, s'han implementat i comparat dos dels algorismes més avançats en l'estat de l'art actual, integrats amb les prediccions del model YOLOv8:

- ByteTrack [21]: Un algorisme caracteritzat per la seva alta velocitat i simplicitat. La seva innovació principal és que no descarta les deteccions de baixa confiança geomètrica, sinó que les aprofita per mantenir les trajectòries en moments de semi-oclusió.
- BoT-SORT [22]: Un algorisme més complex i robust que incorpora compensació del moviment de la càmera i mòduls d'extracció de característiques visuals per recordar l'aparença de l'objecte seguit.

L'avaluació s'ha realitzat sobre un clip de vídeo de prova de 1,5 minuts (aproximadament 2.700 fotogrames) on hi ha presents 10 porcs reals. Per quantificar-ne el rendiment s'han analitzat dues mètriques crítiques: la velocitat de processament en Fotogrames per Segon (FPS), on un valor superior a 30 FPS indica capacitat per funcionar en temps real; i el total d'IDs generats, on un valor superior als 10 porcs reals indica pèrdues de memòria i per tant un mal seguiment. A la Taula 2 es presenten els resultats d'una avaluació inicial utilitzant els paràmetres estàndard per defecte (una memòria temporal de 30 fotogrames i un llindar de confiança del 30 %).

Model	Tracker	FPS	Num. ID
YOLOv8 Nano	ByteTrack	46.53	45
YOLOv8 Nano	BoT-SORT	25.39	46

NOM ESTUDIANT: TÍTOL TREBALL (ABREUJAT SI ÉS MOLT LLARG)

YOLOv8 Small	ByteTrack	45.84	43
YOLOv8 Small	BoT-SORT	21.81	45

Taula 2. Resultats base del seguiment temporal (Confiança: 0.3 | Memòria: 30 frames).

Com es pot veure, la configuració base provoca greus problemes de rendiment, generant més de 40 IDs per a només 10 porcs. Per tant s'ha decidit fer un estudi d'optimització de paràmetres per a buscar la millor combinació possible.

7.4 Optimització de seguiment

Davant del problema de fragmentació, s'ha hagut de dissenyar un experiment per a provar les diverses combinacions de memòria temporal (*Track Buffer*) i el llindar de confiança, per al model *YOLOv8 nano i small* i per als dos algorismes de seguiment ByteTrack i pel BoT-SORT.

L'estudi mostra que pujar el llindar de confiança al 90 % (0.9) i estendre la memòria a 120 fotogrames és la combinació que dona millors resultats. Aquesta combinació permet que el model ignori deteccions dubtoses que podrien generar IDs nous per error, i confii en la memòria del buffer per recuperar l'animal un cop torna a veure's amb claredat. A la Taula 3 es mostren les configuracions que han donat millor resultat.

Model	Tracker	Memòria	Conf.	FPS	IDs
YOLOv8 Nano	BoT-SORT	120	0.9	26.38	10
YOLOv8 Nano	ByteTrack	120	0.9	49.22	11
YOLOv8 Small	ByteTrack	120	0.9	52.24	18

Taula 3. Configuracions òptimes després de l'estudi d'optimització.

Després de fer certes validacions manuals per a comprovar el correcte funcionament dels algorismes, s'ha pogut veure que gràcies a la memòria de fotogrames i el nivell de confiança a 0.9 fa un bon *tracking* dels porcs i dels seus IDs corresponents. Tot i això, s'observa que hi ha certes situacions (com es pot comprovar a la Figura 5) en què, per culpa de les poques imatges d'entrenament i el llindar de confiança tan alt, es perd temporalment la detecció de l'animal, tot i que gràcies a la memòria el recupera al cap d'un o dos segons màxim. Aquest fet, ara mateix no suposa cap problema, tot i que més endavant per a calcular distància recorreguda de l'animal o altres paràmetres que poden ser claus per detectar certs patrons de comportament podrien afectar.




Figura 5: Imatge problema pèrdua animals.

Per últim, cal parlar sobre la velocitat de processament o (FPS) a la qual es capaç de treballar el nostre algorisme. Actualment, no és un paràmetre que ens hagi d'afectar, ja que per a vídeos curts i analitzats en diferit no suposa un problema. Però, més endavant quan es vulgui aplicar aquest model a una granja real, haurà de tenir una velocitat de processament superior o igual que la dels vídeos que obtenim del nostre client. El no complir amb aquest paràmetre podria suposar un retard constant i acumulat (latència) derivant en la impossibilitat d'analitzar els porcs en directe. Actualment, per exemple, el nostre model YOLOv8 BoT-SORT (a 26 FPS) no compliria amb els estàndards mínims d'una càmera estàndard de 30 FPS, però en canvi, el YOLOv8n ByteTrack sí que els compliria amb escreix.

7.5 Conclusions de l'apartat tècnic

Amb aquests experiments es tanca la fase de Visió 2D de l'Sprint 2 amb les següents conclusions:

1. Selecció del model: El model YOLOv8 Small s'ha consolidat com el més precís per a la segmentació, tot i que el model Nano és el més eficient per al seguiment en temps real. Això s'ha assolit gràcies a l'estudi d'optimització, assumint un petit intercanvi: s'accepten pèrdues temporals de la detecció per culpa d'un llindar de confiança alt, confiant en la memòria del buffer per recuperar la identitat de l'animal un o dos segons després.
2. Èxit en l'estabilitat: S'ha aconseguit reduir la fragmentació de 46 a 10 IDs, resolent el principal obstacle tècnic del seguiment d'animals idèntics.
3. Millor configuració: La combinació de ByteTrack amb alta confiança i buffer extens s'estableix com el motor de seguiment en aquesta part del projecte, ja que manté una precisió quasi perfecta amb una fluïdesa de gairebé 50 FPS. Assolir aquesta velocitat garanteix que, en aplicar el model a una granja real en el futur, el sistema podrà processar els vídeos sense patir retards acumulats ni problemes de latència en directe.

8 ESTAT DE L'ART

Per contextualitzar les decisions tecnològiques preses durant el desenvolupament d'aquest projecte, és necessari

realitzar una revisió de l'estat actual. A continuació, es detallen els diferents models, xarxes neuronals i algorismes matemàtics que formen la base teòrica del treball, dividits segons la seva finalitat pràctica.

8.1 Models de Detecció i Segmentació

Aquesta categoria engloba les arquitectures encarregades de localitzar els objectes i extreure'n la silueta en un fotograma estàtic.

- **Mask R-CNN:** És una arquitectura de detecció de dues etapes (two-stage) que va marcar un abans i un després en la segmentació. El model primer genera propostes de regions on creu que hi ha un objecte i, posteriorment, les classifica i en genera la màscara exacta a nivell de píxel. Tot i oferir una precisió geomètrica molt alta, el seu elevat cost computacional la fa inviable per processar vídeo en temps real en dispositius de granja [13].
- **SSD (Single Shot MultiBox Detector):** Aquest model de detecció d'una sola etapa (one-stage) es va dissenyar precisament per resoldre la lentitud dels models de dues etapes. L'SSD prediu les bounding boxes i les classes directament en una única passada de la xarxa neuronal, fet que el fa extremadament ràpid. Tot i la seva agilitat, històricament presenta dificultats per detectar objectes petits o molt densos en comparació amb altres arquitectures [14].
- **YOLO (You Only Look Once):** És la família de models d'una sola etapa més utilitzada en la indústria actual i l'escollida com a motor base d'aquest projecte. YOLO analitza la imatge dividint-la en una quadrícula per processar la detecció com un únic problema de regressió, aconseguint resultats pràcticament instantanis. En les seves versions més recents, com YOLOv8, incorpora segmentació de màscares molt precises, oferint un equilibri òptim entre cost computacional i rendiment operatiu [7].

8.2 Associació temporal

Aquests elements permeten a l'ordinador relacionar i recordar l'aspecte dels diferents individus.

- **Hungarian Algorithm:** És un mètode matemàtic clàssic d'optimització dissenyat per resoldre problemes d'assignació. En el seguiment d'objectes, s'utilitza per emparellar de manera eficient les deteccions del fotograma actual amb les trajectòries conegudes del fotograma anterior. L'algorisme busca la combinació que minimitzi el "cost" global de l'assignació, que habitualment es calcula en funció de la distància física entre els objectes [15].
- **AutoEncoder:** És una xarxa neuronal no

supervisada dissenyada per aprendre a comprimir i representar dades de manera eficient. Funciona forçant la informació visual d'entrada a passar per un procés de compressió, reduint-la a un vector de característiques (*embedding*), per després intentar reconstruir-la. En l'àmbit de la visió artificial, s'utilitza com a eina per extreure els trets visuals més importants d'una imatge descartant-ne el soroll, permetent així diferenciar i recordar l'aspecte únic de cada animal [16].

- **Re-Identification (ReID):** És el mòdul encarregat de reconèixer la identitat d'un mateix individu al llarg del temps o a través de diferents càmeres. El sistema extreu un vector de característiques visuals úniques de l'animal, basant-se en la textura o el color. Així, quan un porc pateix una oclusió i torna a ser visible, el mòdul compara els vectors emmagatzemats per confirmar si es tracta del mateix individu [17].

8.3

Els algorismes MOT (Multi-Object Tracking) fusionen les deteccions espacials amb els mètodes d'associació per assignar identificadors (IDs) continus als vídeos.

- **SORT (Simple Online and Realtime Tracking):** És un enfocament molt pràctic i ràpid per al seguiment d'objectes. Utilitza Filtres de Kalman per predir on es trobarà l'objecte en el següent fotograma, i *Hungarian Algorithm* per associar-lo. Tot i ser molt eficient a nivell de processament, pateix un problema sever de fragmentació (ID Switches) quan els objectes s'oculten entre ells [18].
- **DeepSORT:** Neix com a evolució directa de SORT per resoldre les pèrdues d'identitat durant les oclusions. La seva principal aportació és la integració d'un mòdul descriptor d'aparença profunda (ReID) basat en una xarxa neuronal. Gràcies a això, DeepSORT assoleix una associació molt més robusta, relacionant els objectes no només per la seva posició física predita, sinó també per les seves característiques visuals [19].
- **Norfair:** És una llibreria de seguiment de codi obert dissenyada específicament per ser molt lleugera i adaptable. A diferència de DeepSORT, Norfair no usa xarxes neuronals pesades per a l'extracció d'aparença, i basa l'associació en funcions de distància heurístiques definides pel mateix usuari. Aquesta manera de funcionar el fa ideal per a entorns de monitoratge controlats o per a execucions en dispositius amb molt poca capacitat de càlcul [20].

- **ByteTrack:** Millora als anteriors no descartant automàticament les deteccions de baixa confiança. En lloc d'eliminar-les, les recupera en un procés d'associació secundari, aconseguint mantenir trajectòries estables durant oclusions complexes [21].
- **BoT-SORT (Robust Associations Multi-Object Tracking):** És actualment un dels algorismes més precisos i robusts. Aquest model millora DeepSORT integrant un sistema de compensació del moviment de la càmera (CMC) i un mòdul ReID molt avançat. Tot i que proporciona una gran estabilitat en la conservació dels IDs, la seva alta càrrega de processament penalitza significativament la quantitat de fotogrames per segon (FPS), dificultant el seu ús en directe de forma pràctica[22].

ÚS DE LA IA GENERATIVA

Per a la redacció d'aquest informe inicial s'ha fet ús de Google Gemini [6], una eina basada en IA generativa amb l'únic propòsit de millorar l'expressió escrita i avaluar diferents opcions de disseny tècnic. Per altra banda, s'ha utilitzat per a crear el codi python a partir de les especificacions d'objectius, fites i sprints creats per a fer el diagrama de Gantt (*Figura 1*) completament personalitzat.

En l'àmbit del desenvolupament de software, la IA s'ha emprat exclusivament com un assistent tècnic per depurar errors (debugging), optimitzar la sintaxi i aportar idees en el disseny dels experiments. Aquest ús s'ha fet sota un criteri estrictament ètic, garantint sempre que la lògica algorítmica i l'autoria del codi recauen íntegrament en l'alumne.

Tot i que ha servit com a suport per reformular textos i analitzar possibles enfocaments metodològics, la direcció del projecte, el contingut i les decisions finals adoptades en aquest document s'han establert de manera completament autònoma i manual.

BIBLIOGRAFIA

[1] IRTA, "Centre de Control i Avaluació de Porcí," Institut de Recerca i Tecnologia Agroalimentàries. [En línia]. Disponible a: <https://www.irta.cat/centres/control-i-avaluacio-de-porci-cap/>

[2] Centre de Visió per Computador (CVC), Universitat Autònoma de Barcelona. [En línia]. Disponible a: <https://www.cvc.uab.es/>

[3] Ministerio de Agricultura, Pesca y Alimentación (MAPA), "Indicadores económicos del sector de la carne de cerdo en cifras 2024," 2024. [En línia]. Disponible a: <https://www.mapa.gob.es/dam/mapa/contenido/ganaderia/temas/produccion-y-mercados-ganaderos/sectores-ganaderos-2/porcino/informacion-del-sector/indicadores-economicos/indicadores-sector-de-la-carne-de-cerdo-en-cifras-2024.pdf>

[4] Porcat, "La carn de porc representa el 34% de la producció mundial càrnia segons la FAO," 2024. [En línia]. Disponible a:

https://www.porcat.org/ca/noticies/la-carn-de-porc-representa-el-34-de-la-produccio-mundial-carnia-segons-la-fao_3282/

[5] Trello, "Eina de gestió de projectes i tasques," Atlassian. [En línia]. Disponible a: <https://trello.com/>

[6] Google, "Gemini: Intel·ligència Artificial Generativa," 2024. [En línia]. Disponible a: <https://gemini.google.com/>

[7] Ultralytics, "Ultralytics Docs: YOLOv8 and Vision AI documentation," 2024. [En línia]. Disponible a: <https://docs.ultralytics.com/>

[8] GitHub, "Plataforma de desenvolupament col·laboratiu i control de versions," 2026. [En línia]. Disponible a: <https://github.com/>

[9] Meta AI, "Segment Anything Model (SAM): A new AI model for image segmentation," 2023. [En línia]. Disponible a: <https://segment-anything.com/>

[10] Meta AI, "Segment Anything Model 2 (SAM 2): Real-time segmentation for video and images," 2024. [En línia]. Disponible a: <https://ai.meta.com/blog/segment-anything-2/>

[11] MIT 6.S191, "Introduction to Deep Learning," Massachusetts Institute of Technology (YouTube Course). [En línia]. Disponible a: https://www.youtube.com/watch?v=al-fdI7S6wCY&list=PLtBw6njQRU-rwp5_7C0oIVt26ZgjG9NI

[12] Kaggle, "Kaggle Learn: Practical Machine Learning and Data Science courses," 2024. [En línia]. Disponible a: <https://www.kaggle.com/learn>

[13] K. He, G. Gkioxari, P. Dollár i R. Girshick, "Mask R-CNN", Proceedings of the IEEE international conference on computer vision, pp. 2961-2969, 2017. [En línia]. Disponible a: <https://arxiv.org/abs/1703.06870>

[14] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu i A. C. Berg, "SSD: Single shot multibox detector", European conference on computer vision (ECCV), pp. 21-37, 2016. [En línia]. Disponible a: <https://arxiv.org/abs/1512.02325>

[15] H. W. Kuhn, "The Hungarian method for the assignment problem", Naval research logistics quarterly, vol. 2, núm. 1-2, pp. 83-97, 1955. [En línia]. Disponible a: <https://doi.org/10.1002/nav.3800020109>

[16] M. A. Kramer, "Nonlinear principal component analysis using autoassociative neural networks", AIChE journal, vol. 37, núm. 2, pp. 233-243, 1991. [En línia]. Disponible a: <https://doi.org/10.1002/aic.690370209>

[17] M. Ye, J. Shen, G. Lin, T. Xiang, L. Shao i S. C. Hoi, "Deep learning for person re-identification: A review and outlook", IEEE transactions on pattern analysis and machine intelligence, 2021. [En línia]. Disponible a: <https://arxiv.org/abs/2001.04193>

[18] A. Bewley, Z. Ge, L. Ott, F. Ramos i B. Upcroft, "Simple online and realtime tracking", 2016 IEEE international conference on image processing (ICIP), 2016. [En línia]. Disponible a: <https://arxiv.org/abs/1602.00763>

[19] N. Wojke, A. Bewley i D. Paulus, "Simple online and realtime tracking with a deep association metric", 2017 IEEE international conference on image processing (ICIP), 2017. [En línia]. Disponible a: <https://arxiv.org/abs/1703.07402>

[20] Tryolabs, "Norfair: Lightweight Python library for adding real-time 2D object tracking to any detector", 2020. [En línia]. Disponible a: <https://github.com/tryolabs/norfair>

[21] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan i X. Wang, "ByteTrack: Multi-object tracking by associating every detection box", European Conference on Computer Vision (ECCV), 2022. [En línia]. Disponible a: <https://arxiv.org/abs/2110.06864>

[22] N. Aharon, R. Orfaig i B. Z. Bobrovsky, "BoT-SORT: Robust associations multi-object tracking", arXiv preprint arXiv:2206.14651, 2022. [En línia]. Disponible a: <https://arxiv.org/abs/2206.14651>

[23] G. Bradski, "The OpenCV Library", Dr. Dobb's Journal of Software Tools, 2000. [En línia]. Disponible a: <https://opencv.org/>

[24] OpenCV, "Computer Vision Annotation Tool (CVAT)", 2024. [En línia]. Disponible a: <https://www.cvat.ai/>

[25] Meta AI, "Segment Anything Model 3 (SAM 3)", 2025. [En línia]. Disponible a: <https://ai.meta.com/blog/segment-anything-model-3/>