

Detecció de Comportament i Estimació de Pes de Porcs amb Visió 2D i 3D

Pere Llauradó Adeva

1 INTRODUCCIÓ

El meu avi, que va ser pastor i ramader de xais des dels 6 anys, podia dir per experiència si un animal estava malalt, estressat o tenia problemes de creixement a ull nu, sense cap mena de tecnologia. Actualment, se sacrifiquen més de 52 milions de porcs només a l'Estat espanyol, i la població porcina ha augmentat més d'un 133% en els últims 28 anys [3]. Davant d'aquest augment desmesurat, és molt important garantir el benestar de cada animal durant la seva estada a la granja; però, avui dia, som incapaços de vigilar i garantir aquest benestar a simple vista.

Al mateix temps, a la carnisseria de la meva mare puc presenciar la pressió que rep aquest sector. El preu del porc no ha parat d'augmentar, sent un dels productes que més ha impulsat la inflació alimentària i arribant a registrar increments interanuals d'un 13,6% segons l'IPC [3]. A més, el consumidor exigeix cada cop una producció més ètica i amb certes certificacions que garanteixin el benestar animal [4]. Amb uns costos de producció tan disparats, els marges de benefici tant de carnisseres com de grangers s'estan reduint de manera preocupant. Com es pot assegurar una vida digna als animals sense ofegar econòmicament els ramaders?

Aquest TFG proposa crear un "pastor digital" mitjançant tècniques d'Intel·ligència Artificial i Visió per Computador (utilitzant dades 2D i 3D de l'IRTA [1] i el CVC [2]) per monitorar de forma autònoma el comportament, la salut i el pes dels porcs. Així, la tecnologia esdevé una solució pràctica i no invasiva per garantir el benestar animal i, alhora, millorar la rendibilitat econòmica de les granges. L'objectiu d'aquest informe inicial és, doncs, establir-ne les bases tècniques i metodològiques.

2 CONTEXTUALITZACIÓ

Aquest Treball de Final de Grau se centra en el disseny i desenvolupament d'un sistema basat en Visió per Computador i Deep Learning per a l'anàlisi automatitzat del comportament i l'estimació de pes de porcs en entorns reals de granja. Mitjançant l'ús combinat d'imatges 2D i dades volumètriques 3D, capturades en col·laboració amb l'IRTA [1] i el Centre de Visió per Computador de la UAB [2], el projecte busca proporcionar eines tecnològiques avançades per a la gestió ramadera.

Actualment, el monitoratge a les explotacions es realitza en gran mesura de manera manual, la qual cosa resulta costosa i limitada en el temps. Aquest projecte neix amb la voluntat de solucionar aquesta mancança i es fonamenta en tres pilars de motivació principals:

- **Millora del benestar animal:** La implementació d'aquesta eina permetrà tenir informació constant (24 hores al dia, 7 dies a la setmana) sobre el comportament, l'evolució del pes, l'estat de salut, etc. Això s'aconsegueix de manera contínua, no invasiva i sense la necessitat de tenir un operari present constantment.
- **Optimització del rendiment i benefici ramader:** L'automatització d'aquest monitoratge permetrà als ramaders tenir els animals molt més vigilats i atesos, anticipant-se a possibles malalties o problemes de creixement. Alhora, aquesta eficiència redueix la dependència de mà d'obra intensiva per a tasques d'observació, millorant així l'escalabilitat i els marges de benefici de les granges.
- **Motivació personal i vincle familiar:** Més enllà del repte tècnic que suposa la intel·ligència artificial, aquest projecte té una forta component personal. Els meus orígens familiars estan estretament lligats al sector: el meu avi va ser pastor i granger de xais, la família del meu pare tenia porcs, i la meva mare regenta una carnisseria. Aquest bagatge i connexió amb el món rural i la indústria càrnica em generen una il·lusió i una motivació especials per aplicar els meus coneixements d'enginyeria per aportar valor a un sector tan proper a mi.

3 OBJECTIUS

L'objectiu principal d'aquest Treball de Final de Grau és dissenyar, desenvolupar i avaluar un sistema basat en Visió per Computador i models de Deep Learning per automatitzar el monitoratge del comportament, prevenció de malalties i l'estimació de pes de porcs en entorns de granja, usant càmeres 2D i 3D.

Per assolir aquesta fita, l'abast del projecte es desglossa en els següents objectius específics:

- **Definició de requeriments i mètriques clíniques:** Analitzar les necessitats reals de gestió ramadera i benestar animal mitjançant entrevistes i col·laboració directa amb professionals del sector (veterinaris

porcins), per tal de definir quins comportaments, malalties i marges d'error en el pes són crítics a monitorar o més imprescindibles per a fer més pràctic el nostre sistema.

- **Tractament de dades:** Processar, estructurar i etiquetar un dataset d'imatges 2D i dades volumètriques 3D, capturat i proporcionat en una granja experimental en col·laboració amb l'IRTA [1] i el Centre de Visió per Computador [2] (CVC) de la UAB.
- **Desenvolupament de models de segmentació:** Entrenar i implementar models de Deep Learning capaços de segmentar i identificar de manera individualitzada cada porc dins dels corrals a partir de les imatges capturades i detectar quin de tots té un millor rendiment.
- **Anàlisi de comportament i estimació de pes:** Desenvolupar els algorismes necessaris de deep learning per classificar els patrons de moviment/comportament detectats i dissenyar un mètode precís per calcular el pes dels animals aprofitant les dades espacials (3D).
- **Avaluació i comparativa tècnica:** Comparar diferents tipus d'algorismes com la llibreria YOLO [7], algorismes CNN i altres tècniques clàssiques de VC. Per veure quin dona millor rendiment i més òptim.

Per a l'organització d'aquest TFG s'ha optat per una adaptació de la metodologia àgil (Agile), ajustada a les necessitats d'un únic desenvolupador. El treball s'estructurarà Sprints de 5 setmanes, corresponent-se cada un amb les entregues corresponents. S'ha optat a iteracions més llargues del que és habitual, ja que els models de Deep Learning a entrenar i les dades a processar requeriran llargs temps d'execució, d'aquesta manera es podrà realitzar entregables al final de cada Sprint molt més complets.

Per a la planificació i el seguiment diari de les tasques, es farà ús d'un tauler Kanban mitjançant la plataforma Trello [5]. S'ha prioritzat aquesta eina ja que permet organitzar el projecte de manera molt visual, senzilla i amb moltes opcions d'edició diferents. A més, independentment de la gestió de tasques, tot el control de versions del codi, l'històric d'entrenaments i els experiments amb els models d'intel·ligència artificial es gestionaran de manera centralitzada mitjançant GitHub [8].

El desenvolupament del TFG consta de 20 setmanes i 4 entregues diferents, amb una càrrega de treball aproximada de 300 hores. S'han alineat els diferents sprints i objectius amb les fites d'avaluació. Com s'ha explicat anteriorment,

cada sprint té una durada exacta de 5 setmanes.

Sprint 1: Fonamentació i Planificació (Febrer - Març)

Aquest primer cicle (actualment finalitzat) ha correspost a la fase introductòria i "filosofal" del projecte. S'ha dedicat a entendre el problema, establir l'abast tècnic i clínic amb el veterinari, preparar les eines de gestió (Trello, repositoris) i estructurar documentalment el treball. Aquesta fase conclou amb el lliurament de l'Informe Inicial (Setmana 4).

Sprint 2: Inici Tècnic i Visió 2D (Març - Abril)

Inici del desenvolupament pràctic, on s'acaben de definir els requeriments més específics amb els veterinaris. Abasta des de la recepció, neteja i etiquetatge de les imatges, fins a l'inici de l'entrenament dels primers models 2D com són CNN i YOLO [7] per detectar les siluetes dels porcs i els comportaments més bàsics. Finalitza amb el lliurament de l'Informe de Progrés I (Setmana 10).

Sprint 3: Integració 3D i Comportament (Abril - Maig)

Aquesta iteració es focalitza a afegir la profunditat espacial. S'incorporen els mapes de profunditat (3D) per desenvolupar els algorismes d'estimació de pes i es programa la lògica per classificar les postures i anomalies de comportament. La fita d'aquest cicle és el lliurament de l'Informe de Progrés II (Setmana 14).

Sprint 4: Avaluació i Tancament (Maig - Juny)

L'últim esprint es destina exclusivament a l'anàlisi de resultats (comparant l'error entre els diferents models i la fusió 2D+3D), al desenvolupament d'una interfície senzilla per avisar els veterinaris i grangers, a l'optimització del codi i a la redacció de la memòria completa. Per a aquesta darrera etapa, les fites oficials són: Proposta Informe Final (Set. 17), Proposta Presentació (Set. 19), Lliurament Final (abans del 29 de juny) i Defensa Pública (del 3 al 8 de juliol).

A continuació, a la *Figura 1*, es mostra el diagrama de Gantt de la planificació. El gràfic permet veure ràpidament com es distribueix la càrrega de treball al llarg de les 20 setmanes i com cada esprint quadra amb les fites de la universitat.




Figura 1: diagrama de Gantt

6 SEGUIMENT DE LA PLANIFICACIÓ

El desenvolupament del Treball de Final de Grau segueix de prop la planificació establerta al diagrama de Gantt presentat en l'Informe Inicial.

6.1 Fase 1

Pel que fa al nivell de seguiment, s'han assolit amb èxit tots els objectius tècnics previstos per a aquesta etapa: s'ha implementat el flux de processament de dades, s'han entrenat els models de segmentació i s'ha optimitzat el sistema de seguiment múltiple (Multi-Object Tracking).

L'únic ajust rellevant respecte a la previsió inicial ha estat derivat del lleuger retard en l'obtenció de les dades definitives per part de la granja experimental de l'IRTA. Lluny de suposar un bloqueig, aquest temps s'ha invertit de manera proactiva en realitzar l'estudi avançat d'hiperparàmetres detallat en l'apartat anterior utilitzant imatges d'arxiu. Aquesta decisió estratègica ha permès construir una base de codi (pipeline) completament automatitzada i depurada.

En conseqüència, no es considera necessari introduir cap modificació estructural en el calendari ni en els objectius globals del TFG. Un cop es rebin els vídeos i mapes de profunditat actualitzats de l'IRTA, el reentrenament del model serà immediat gràcies a la infraestructura ja programada, permetent iniciar l'Sprint 3 (Integració 3D i Comportament) dins dels terminis acadèmics establerts.

7 DESENVOLUPAMENT

A continuació, es detallen els procediments duts a terme per assolir amb èxit els objectius establerts a l'apartat 5. Aquest capítol recull tota l'evolució tècnica del projecte de forma cronològica: des del processament inicial de les dades 2D, l'entrenament dels models de segmentació i seguiment, fins a la implementació de la solució definitiva per resoldre el seguiment temporal i l'estimació del pes dels animals en temps real.

7.1 Preparació de les dades d'entrenament

En primer lloc, s'han obtingut els vídeos dels animals del

2021, enregistrats en un corral amb 10 porcs. A partir d'un script en Python i de la llibreria OpenCV [23], s'han processat els 4 vídeos i se n'han extret automàticament fotogrames cada 25 segons. L'objectiu d'aquest mostreig temporal és crear un *dataset* amb imatges el més diverses possible, per a evitar la semblança entre elles i, per tant, el subajustament (*underfitting*) en certes situacions i el sobreajustament (*overfitting*) en altres. S'han extret exactament 100 imatges, tal com es mostra a la Figura 2.



Figura 1: Fotograma extret sense tractar.

Seguidament, s'ha procedit a l'etiquetatge manual utilitzant l'aplicació web CVAT [24]. Aquesta eina s'ha combinat amb el model SAM 3 [25] (Segment Anything Model 3), la IA de Meta enfocada en la segmentació d'imatges i vídeos. Aquesta integració ha permès crear etiquetes per a cada porc, marcant la posició exacta de cadascun de manera molt precisa per a generar les màscares de cada fotograma que formen la base de dades d'entrenament (Figura 3). En total, s'han preparat 86 imatges d'entrenament i validació, un volum suficient per a dur a terme una prova de concepte inicial amb l'arquitectura YOLOv8.



Figura 3: Imatge processada per SAM a la interfície CVAT.

7.2 Entrenament dels models de segmentació

Un cop preparat i etiquetat el conjunt de dades, s'ha procedit a l'entrenament dels models. Després d'investigar totes les possibilitats per a crear un model basat en xarxes neuronals convolucionals (CNN), s'ha vist que pel volum de dades que tenim, per a un millor rendiment i per a uns resultats ràpids i amb un bon *accuracy* YOLOv8 era la millor opció.

Per tal de trobar l'equilibri òptim entre cost computacional i precisió geomètrica, s'ha plantejat un experiment comparatiu entrenant tres variants d'aquesta arquitectura:

- YOLOv8 Nano (yolov8n-seg): El model més

lleuger i ràpid.

- YOLOv8 Small (yolov8s-seg): Un model amb una xarxa neuronal més profunda i major nombre de paràmetres.
- YOLOv8 Medium (yolov8m-seg): Un model de complexitat superior als anteriors per a comprovar si realment hi ha risc d'*overfitting* amb la base de dades que disposem actualment.

Els tres models s'han entrenat de forma idèntica durant 50 èpoques (epochs) amb una resolució d'imatge de 640 píxels. Per avaluar el rendiment de cada arquitectura sobre el conjunt d'imatges de validació, s'ha utilitzat la mètrica estàndard mAP50 (Mean Average Precision amb un llindar d'Intersecció sobre Unió del 50%).

A la Taula 1 es mostren els resultats quantitatius obtinguts en aquest primer experiment de prova de concepte:

Model	T. train	mAP50 (Màscara)	mAP50-95
YOLOv8 Nano	3.92	95.18	76.79
YOLOv8 Small	4.37	95.50	80.20
YOLOv8 Medium	8.07	96.06	80.20

Taula 1 resultats rendiment dels 3 models

L'anàlisi d'aquestes dades mostra que l'arquitectura Small presenta un millor rendiment respecte el model Nano. Tot i que en el llindar base (mAP50) la diferència és subtil (d'un 0,32% en la segmentació), la millora es fa especialment evident en la mètrica mAP50-95, on el model Small supera el Nano en un 3,41% (80,20 % vs. 76,79 %). Aquest increment demostra que la major complexitat de la xarxa Small permet detectar les siluetes dels porcs amb molta més precisió.

D'altra banda, en observar els resultats del model Medium, es confirma la hipòtesi inicial: el temps d'entrenament pràcticament es duplica (passant de 4,37 a 8,07 minuts), però la precisió estricta (mAP50-95) es manté idèntica en un 80,20%. Aquests resultats ens mostren que afegir més paràmetres a la xarxa no aporta cap benefici real, ja que augmenta pràcticament el doble el temps d'execució i la precisió es manté.

Tenir una bona *accuracy* en *frames* estàtics és molt important, ja que repercuteix directament en el rendiment dels algorismes de tracking. Aquests resultats són suficientment satisfactoris per a poder continuar amb la fase de seguiment temporal amb els models Nano i Small. No s'usarà el model Medium ja que com veiem no té una millora de rendiment real respecte els altres en aquest cas.

7.3 Implementació dels algorismes de seguiment

Un cop aconseguida una detecció estàtica satisfactòria, seguidament, haurem d'aplicar diferents models per a poder enllaçar aquestes deteccions al llarg del temps.

L'objectiu del seguiment d'objectes múltiples (Multi-Object Tracking, MOT) és assignar un identificador únic (ID) a cada porc i mantenir-lo inalterat durant tota la seqüència de vídeo de la manera més estable possible. Com es pot veure a la Figura 4.



Figura 4: Imatge seguiment porcs amb ID corresponent.

Per dur a terme aquesta tasca, s'han implementat i comparat dos dels algorismes més avançats en l'estat de l'art actual, integrats amb les prediccions del model YOLOv8:

- ByteTrack [21]: Un algorisme caracteritzat per la seva alta velocitat i simplicitat. La seva innovació principal és que no descarta les deteccions de baixa confiança geomètrica, sinó que les aprofita per mantenir les trajectòries en moments de semi-oclusió.
- BoT-SORT [22]: Un algorisme més complex i robust que incorpora compensació del moviment de la càmera i mòduls d'extracció de característiques visuals per recordar l'aparença de l'objecte seguit.

L'avaluació s'ha realitzat sobre un clip de vídeo de prova de 1,5 minuts (aproximadament 2.700 fotogrames) on hi ha presents 10 porcs reals. Per quantificar-ne el rendiment s'han analitzat dues mètriques crítiques: la velocitat de processament en Fotogrames per Segon (FPS), on un valor superior a 30 FPS indica capacitat per funcionar en temps real; i el total d'IDs generats, on un valor superior als 10 porcs reals indica pèrdues de memòria i per tant un mal seguiment. A la Taula 2 es presenten els resultats d'una avaluació inicial utilitzant els paràmetres estàndard per defecte (una memòria temporal de 30 fotogrames i un llindar de confiança del 30 %).

Model	Tracker	FPS	Num. ID
YOLOv8 Nano	ByteTrack	46.53	45
YOLOv8 Nano	BoT-SORT	25.39	46

NOM ESTUDIANT: TÍTOL TREBALL (ABREUJAT SI ÉS MOLT LLARG)

YOLOv8 Small	ByteTrack	45.84	43
YOLOv8 Small	BoT-SORT	21.81	45

Taula 2. Resultats base del seguiment temporal (Confiança: 0.3 | Memòria: 30 frames).

Com es pot veure, la configuració base provoca greus problemes de rendiment, generant més de 40 IDs per a només 10 porcs. Per tant s'ha decidit fer un estudi d'optimització de paràmetres per a buscar la millor combinació possible.

7.4 Optimització de seguiment

Davant del problema de fragmentació, s'ha hagut de dissenyar un experiment per a provar les diverses combinacions de memòria temporal (*Track Buffer*) i el llindar de confiança, per al model *YOLOv8 nano i small* i per als dos algorismes de seguiment ByteTrack i pel BoT-SORT.

L'estudi mostra que pujar el llindar de confiança al 90 % (0.9) i estendre la memòria a 120 fotogrames és la combinació que dona millors resultats. Aquesta combinació permet que el model ignori deteccions dubtoses que podrien generar IDs nous per error, i confii en la memòria del buffer per recuperar l'animal un cop torna a veure's amb claredat. A la Taula 3 es mostren les configuracions que han donat millor resultat.

Model	Tracker	Memòria	Conf.	FPS	IDs
YOLOv8 Nano	BoT-SORT	120	0.9	26.38	10
YOLOv8 Nano	ByteTrack	120	0.9	49.22	11
YOLOv8 Small	ByteTrack	120	0.9	52.24	18

Taula 3. Configuracions òptimes després de l'estudi d'optimització.

Després de fer certes validacions manuals per a comprovar el correcte funcionament dels algorismes, s'ha pogut veure que gràcies a la memòria de fotogrames i el nivell de confiança a 0.9 fa un bon *tracking* dels porcs i dels seus IDs corresponents. Tot i això, s'observa que hi ha certes situacions (com es pot comprovar a la Figura 5) en què, per culpa de les poques imatges d'entrenament i el llindar de confiança tan alt, es perd temporalment la detecció de l'animal, tot i que gràcies a la memòria el recupera al cap d'un o dos segons màxim. Aquest fet, ara mateix no suposa cap problema, tot i que més endavant per a calcular distància recorreguda de l'animal o altres paràmetres que poden ser claus per detectar certs patrons de comportament podrien afectar.




Figura 5: Imatge problema pèrdua animals.

Per últim, cal parlar sobre la velocitat de processament o (FPS) a la qual es capaç de treballar el nostre algorisme. Actualment, no és un paràmetre que ens hagi d'afectar, ja que per a vídeos curts i analitzats en diferit no suposa un problema. Però, més endavant quan es vulgui aplicar aquest model a una granja real, haurà de tenir una velocitat de processament superior o igual que la dels vídeos que obtenim del nostre client. El no complir amb aquest paràmetre podria suposar un retard constant i acumulat (latència) derivant en la impossibilitat d'analitzar els porcs en directe. Actualment, per exemple, el nostre model YOLOv8 BoT-SORT (a 26 FPS) no compliria amb els estàndards mínims d'una càmera estàndard de 30 FPS, però en canvi, el YOLOv8n ByteTrack sí que els compliria amb escreix.

7.5 Conclusions de l'apartat tècnic

Amb aquests experiments es tanca la fase de Visió 2D de l'Sprint 2 amb les següents conclusions:

1. Selecció del model: El model YOLOv8 Small s'ha consolidat com el més precís per a la segmentació, tot i que el model Nano és el més eficient per al seguiment en temps real. Això s'ha assolit gràcies a l'estudi d'optimització, assumint un petit intercanvi: s'accepten pèrdues temporals de la detecció per culpa d'un llindar de confiança alt, confiant en la memòria del buffer per recuperar la identitat de l'animal un o dos segons després.
2. Èxit en l'estabilitat: S'ha aconseguit reduir la fragmentació de 46 a 10 IDs, resolent el principal obstacle tècnic del seguiment d'animals idèntics.
3. Millor configuració: La combinació de ByteTrack amb alta confiança i buffer extens s'estableix com el motor de seguiment en aquesta part del projecte, ja que manté una precisió quasi perfecta amb una fluïdesa de gairebé 50 FPS. Assolir aquesta velocitat garanteix que, en aplicar el model a una granja real en el futur, el sistema podrà processar els vídeos sense patir retards acumulats ni problemes de latència en directe.

8 DESENVOLUPAMENT II

8.1. Evolució i Refinament del model 2D

Un cop establerta l'arquitectura base de seguiment múltiple d'objectes, l'avaluació inicial sobre alguns fragments de vídeo expressament seleccionats (caracteritzats per un alt moviment, oclusions i altres dificultats tècniques) va revelar limitacions severes en entorns de producció reals. El model base entrenat presentava una alta inestabilitat, arribant a registrar desenes d'identificadors (IDs) per a un Ground Truth de només 10 individus. De cara a la posterior integració 3D, ha estat necessari optimitzar l'algorisme mitjançant diverses tècniques de visió per computador.

8.1.1 Limitacions en el model base

Per tal d'entrenar un model més robust, es va procedir a analitzar els resultats empírics de l'algorisme en diversos vídeos. Es va posar el focus en els moments més crítics: aquells on es perdia la identitat dels animals o on es generaven canvis d'ID sense justificació aparent.

- **Disposició de la càmera i il·luminació:** Com s'observa a les figures 6 i 7, tant la perspectiva de la càmera com la incidència directa de la llum solar afecten negativament el rendiment del model. Aquests factors generen pèrdues d'identitat per oclusió amb la paret i la creació de noves identitats a causa dels canvis de color a la pell del porc provocats pel sol. En el nou conjunt de dades, que es detallarà més endavant, es demostrarà l'efecte de comptar amb una càmera disposada òptimament.



Figura 6: Oclusió del porc amb la paret i canvi de tonalitat a causa de la il·luminació




Figura 7:

Identificació anòmla provocada per l'oclusió i la incidència solar

- **Oclusions i solapament (Overlapping):** El comportament natural dels porcs, que tendeixen a descansar amuntegats, provocava que les caixes de delimitadores (bounding boxes) englobessin parts de múltiples individus. Això generava fusions d'identitat temporals i l'aparició de falsos identificadors nous. A més, en situacions d'amuntegament extrem, el sistema aïllava fraccions molt petites del cos de l'animal, fent impossible per a l'extractor de característiques relacionar aquest fragment amb l'individu complet real, creant de nou IDs erronis. Aquest efecte és observable a la figura 8.



Figura 8: Generació d'un nou individu a causa de la falta d'informació per oclusió

- **Intercanvis d'identitat:** En situacions de creuament ràpid entre dos animals, la pèrdua de tracking espacial provocava una fallada en el buffer de memòria, forçant l'algorisme a reassignar identificadors nous, generalment de manera errònia.
- **L'efecte deformador de la bàscula:** Es va detectar que elements estructurals, com els barrots metàl·lics de la menjadora, tallaven la silueta visual de l'animal. Quan el model intentava extreure característiques d'un porc parcialment tapat pels ferros, guardava una representació corrompuda de l'individu. Fins i tot, en moltes situacions, el model reconeixia l'animal com si fossin diversos individus diferents, ja que des de la perspectiva superior la silueta es veia fragmentada, tal com s'il·lustra a la figura 9.



Figura 9: Identificació de diversos individus per culpa de la bàscula

8.1.2 Entrenament model definitiu

Gràcies a l'obtenció de les noves imatges de l'IRTA (de la granja actual) i la necessitat de millorar el model de seguiment dels porcs, es va optar per entrenar un model més potent, com és el YOLOv8m-seg, per millorar la detecció en situacions complexes. A més a més, s'han optat per afegir altres mètodes de millora, que seran explicats a continuació.

Per entrenar aquest model de manera efectiva, es va crear un nou dataset amb unes 220 imatges seleccionades de tots els nous vídeos obtinguts de la granja, on es van etiquetar manualment les siluetes dels porcs. Es va triar la versió Medium del YOLOv8, ja que és el punt intermedi ideal: té prou potència per entendre formes complexes, però no és tan pesat com per anar lent o patir d'overfitting. Tot i que

NOM ESTUDIANT: TÍTOL TREBALL (ABREUJAT SI ÉS MOLT LLARG)
en proves anteriors es va concloure que el model Nano era molt ràpid i eficient per a deteccions simples, a la pràctica s'ha vist que en situacions d'alta oclusió no compleix. El model Medium, tot i requerir un volum de dades més gran per ser entrenat correctament, ofereix una capacitat d'extracció de característiques molt superior, sent capaç de detectar i perfilar els porcs amb molta més precisió en els escenaris més complexos.

Els resultats d'aquest model han estat molt bona. S'ha aconseguit una precisió (segons la mètrica mAP50) de 0.995 sobre el dataset de validació. Això vol dir que el polígon que dibuixa el sistema s'ajusta pràcticament a la perfecció a la silueta real de l'animal.

8.1.3 Auto encoder

Un cop aconseguit un model prou robust i amb una gran precisió, el següent repte era millorar la reidentificació (Re-ID) dels porcs, ja que tot i tenir un model més precís no s'aconseguia millorar els resultats respecte a la pèrdua d'identitat.

Per solucionar aquest problema, el sistema integra un Auto-Encoder, una xarxa neuronal encarregada d'extreure un vector de característiques de cada porc per poder-lo reconèixer més endavant. Entrenar un model específic per reconèixer porcs farà que el nostre model sigui molt més personalitzat i precís.

Per fer l'entrenament del model, es requereixen imatges de porcs amb el fons blanc per tal d'entrenar la xarxa neuronal perquè sigui capaç d'extreure característiques molt precises de cada individu. Per fer-ho, s'ha utilitzat el model YOLOv8m-seg, modificant la configuració del codi perquè extregui 5.000 imatges com les que es poden veure a la *figura 10*, obtingudes de diferents vídeos per millorar al màxim la diversitat de la mostra.



Figura 10:

Silueta d'un porc retallada per a entrenar l'Auto-Encode

8.1.4 Assignació d'identitats i Algorisme Hongarès

Un cop detectats els porcs i extret el seu vector de característiques per l'Auto-Encoder, cal decidir quin ID s'assignarà a cada animal. S'ha hagut de recórrer a una lògica més avançada, ja que hi havia molts moments on diversos porcs tenien percentatges de similitud molt propers i el sistema base assignava els identificadors de manera incorrecta o duplicada. Per tant, es va optar per implementar l'Algorisme Hongarès.

Aquest mètode calcula la similitud entre els vectors, obtenint un percentatge de semblança. Seguidament, avalua totes les similituds possibles entre els porcs detectats a la imatge i els que el sistema té a la memòria, i busca la combinació global més òptima per a tots ells alhora. D'aquesta manera, s'assegura una exclusió mútua estricta: un identificador només pot ser assignat a un únic porc en cada fotograma, eliminant pràcticament la totalitat de les duplicitats i els intercanvis erronis d'identitat.

Per últim, calia evitar situacions com les comentades anteriorment, on el sistema detectava una part molt petita d'un porc (a causa d'una oclusió) i intentava etiquetar-la. Com que l'algorisme no tenia prou informació visual, solia crear un ID nou erroni en no poder reconèixer de qui es tractava realment. Per solucionar-ho, s'ha aplicat un llindar mínim d'àrea per a les deteccions de 6.000 píxels. D'aquesta manera, ens assurem que el sistema només intenti reconèixer l'animal quan en veu una part important, evitant així la creació de nous identificadors sense sentit.

8.1.5 Resultats del nou model

Un cop implementades totes les millores, s'ha provat el sistema amb un vídeo que no s'havia utilitzat per entrenar el model. Aquest era un dels vídeos més complexos de processar, ja que presentava un alt grau de moviment. Un cop processat, el sistema ha detectat un total de 12 identificadors enfront dels 11 porcs reals que hi havia a la granja. A la *figura 11* es mostra un fotograma del funcionament correcte del model.




Figura 11: Fotograma del vídeo de validació mostrant el seguiment correcte

Seguidament, s'ha analitzat exactament en quin punt es produeix l'error d'identificació detectat. A la *figura 12* es pot observar el fotograma on es perd la identitat del porc que es trobava dins la menjadora. Com que l'animal estava dins d'aquesta estructura des de l'inici del vídeo, el sistema va memoritzar la seva silueta deformada pels barrots de ferro. En sortir-ne, el canvi visual va ser tan brusc que l'algorisme no el va reconèixer i va crear un ID nou per equivocació.




Figura 12: Moment de l'error d'identificació en sortir de la bàscula

En conclusió, l'elecció d'un model Medium més robust i el disseny d'un Auto-Encoder especialitzat han resolt els problemes d'intercanvi d'identitats i el soroll de fons del model inicial. El sistema actual és estable i està totalment preparat per afrontar la següent fase del projecte: l'estimació del pes mitjançant la visió 3D.

8.2. Processament 3D i estimació del pes

8.2.1 Creació dataset 3D

Per treballar amb les imatges .ply, el primer pas ha estat preparar i netejar les dades.

En primer lloc, atès que la càmera captura les imatges a 10 bits, s'ha aplicat una transformació mitjançant la llibreria NumPy per passar-les a 8 bits. D'aquesta manera, s'obtenen uns arxius estandarditzats que permeten tant observar-los com processar-los correctament amb el nostre sistema.

Un cop feta aquesta conversió, s'han pogut analitzar les imatges en 3D. Com es pot observar a la figura 13, la càmera té un camp de visió molt més ampli que únicament el corral, capturant altres parts de la granja (altres grups de porcs, parets i estructures innecessàries). Per tal de poder aplicar correctament els models d'IA, s'han hagut de retallar les imatges en els tres eixos espacials (X, Y, Z) per aïllar els volums (blobs) de la millor manera possible, facilitant-ne així la posterior detecció. A la figura 14 es pot observar el resultat d'aquest retall que se li ha aplicat a la imatge.




Figura 13: Núvol de punts original



Figura 14: Núvol de punts retallat mostrant només l'àrea d'interès

8.2.2 Homografia

Un cop preparats i retallats els núvols de punts, el pas següent és establir una correspondència espacial entre aquest entorn tridimensional i les deteccions 2D generades pel model YOLO. Com que la càmera de gravació bidimensional (RGB) i el sensor de profunditat tenen perspectives i camps de visió diferents, no es poden superposar les imatges de manera directa. Per solucionar-ho, cal aplicar una transformació geomètrica coneguda com a Homografia.

Aquest procediment consisteix a extreure les coordenades de quatre punts de referència clars i inamovibles a la imatge 3D (com poden ser les cantonades de la menjadora o marques específiques a terra) i emparellar-los amb els mateixos quatre punts a la imatge 2D.

A partir d'aquests quatre parells de coordenades, l'algorisme calcula la matriu d'homografia. Aquesta matriu actua com un pont matemàtic que tradueix les coordenades d'un pla a l'altre, tal com s'il·lustra a la figura 15. Cal tenir en compte que, com que actualment no es disposa d'imatges enregistrades en el mateix instant de temps per a totes dues càmeres, no es podrà realitzar una correspondència perfecta amb els porcs en moviment; malgrat això, serà completament suficient per validar com funciona la transformació sobre l'estructura del corral. Finalment, aquesta operació permetrà agafar el polígon exacte del porc detectat en el vídeo i projectar-lo sobre el núvol de punts 3D.



Figura 15: Resultat de prova homografia

Per fer l'homografia de prova que es mostra a la figura 15, s'ha utilitzat la imatge 3D sense retallar l'eix Z per tal de mantenir la referència del terra i apreciar el resultat d'una manera més il·lustrativa. D'altra banda, s'ha projectat un quadrat verd a la imatge 2D inicial per poder avaluar visualment i de manera clara l'efecte de la transformació geomètrica sobre l'espai tridimensional.

8.2.3 Integració 2D i 3D

Un cop feta l'homografia, el darrer pas del procés consisteix a connectar el món 2D i el 3D per a poder conèixer el pes de cada porc per separat. Per fer-ho, s'haurà d'aïllar la silueta exacta en 3D de l'animal a partir del seguiment que es fa en 2D. Seguidament, es disposa d'un fitxer Excel facilitat per l'IRTA on es registren els pesos exactes de cada animal en el moment en què accedeix a la bàscula. Gràcies a la correspondència entre la càmera bidimensional, la tridimensional i les dades esmentades anteriorment, es podrà entrenar un model capaç de predir el pes del porc a partir del seu volum.

Actualment, però, la implementació d'aquesta última fase s'ha trobat amb un obstacle. Les imatges 3D emmagatzemades en els fitxers .ply no contenen cap marca de temps a les seves metadades. Aquesta absència de referència temporal fa que sigui impossible relacionar les imatges 3D amb els fotogrames del vídeo 2D, ni tampoc amb el registre de pesos de l'Excel.

Com a conseqüència, s'haurà d'esperar a rebre aquesta informació per part de l'IRTA. Mentrestant, es deixarà tot preparat (el model 2D, les imatges 3D retallades i el codi a punt per fer l'homografia correctament) per poder entrenar el model predictor de pes de la manera més ràpida i àgil possible.

9 ESTAT DE L'ART

Per contextualitzar les decisions tecnològiques preses durant el desenvolupament d'aquest projecte, és necessari realitzar una revisió de l'estat actual. A continuació, es detallen els diferents models, xarxes neuronals i algorismes matemàtics que formen la base teòrica del treball, dividits segons la seva finalitat pràctica.

9.1 Models de Detecció i Segmentació

Aquesta categoria engloba les arquitectures encarregades de localitzar els objectes i extreure'n la silueta en un fotograma estàtic.

- **Mask R-CNN:** És una arquitectura de detecció de dues etapes (two-stage) que va marcar un abans i un després en la segmentació. El model primer genera propostes de regions on creu que hi ha un objecte i, posteriorment, les classifica i en genera la màscara exacta a nivell de píxel. Tot i oferir una precisió geomètrica molt alta, el seu elevat cost computacional la fa inviable per processar vídeo en temps real en dispositius de granja [13].
- **SSD (Single Shot MultiBox Detector):** Aquest model de detecció d'una sola etapa (one-stage) es va dissenyar precisament per resoldre la lentitud dels models de dues etapes. L'SSD prediu les bounding boxes i les classes directament en una única passada de la xarxa neuronal, fet que el fa extremadament ràpid. Tot i la seva agilitat, històricament presenta dificultats per detectar objectes petits o molt densos en comparació amb altres arquitectures [14].
- **YOLO (You Only Look Once):** És la família de models d'una sola etapa més utilitzada en la indústria actual i l'escollida com a motor base d'aquest projecte. YOLO analitza la imatge dividint-la en una quadrícula per processar la detecció com un únic problema de regressió, aconseguint resultats pràcticament instantanis. En les seves versions més recents, com YOLOv8, incorpora segmentació de màscares molt precises, oferint un equilibri òptim entre cost computacional i rendiment operatiu [7].

9.2 Associació temporal

Aquests elements permeten a l'ordinador relacionar i recordar l'aspecte dels diferents individus.

- **Hungarian Algorithm:** És un mètode matemàtic clàssic d'optimització dissenyat per resoldre problemes d'assignació. En el seguiment d'objectes, s'utilitza per emparellar de manera eficient les deteccions del fotograma actual amb les trajectòries conegudes del fotograma anterior. L'algorisme busca la combinació que minimitzi el "cost" global de l'assignació, que habitualment es calcula en funció de la distància física entre els objectes [15].
- **AutoEncoder:** És una xarxa neuronal no supervisada dissenyada per aprendre a comprimir i representar dades de manera eficient. Funciona forçant la informació visual d'entrada a passar per un procés de compressió, reduint-la a un vector de característiques (*embedding*), per després intentar reconstruir-la. En l'àmbit de la visió artificial, s'utilitza

com a eina per extreure els trets visuals més importants d'una imatge descartant-ne el soroll, permetent així diferenciar i recordar l'aspecte únic de cada animal [16].

- **Re-Identification (ReID):** És el mòdul encarregat de reconèixer la identitat d'un mateix individu al llarg del temps o a través de diferents càmeres. El sistema extreu un vector de característiques visuals úniques de l'animal, basant-se en la textura o el color. Així, quan un porc pateix una oclusió i torna a ser visible, el mòdul compara els vectors emmagatzemats per confirmar si es tracta del mateix individu [17].

9.3

Els algorismes MOT (Multi-Object Tracking) fusionen les deteccions espacials amb els mètodes d'associació per assignar identificadors (IDs) continus als vídeos.

- **SORT (Simple Online and Realtime Tracking):** És un enfocament molt pràctic i ràpid per al seguiment d'objectes. Utilitza Filtres de Kalman per predir on es trobarà l'objecte en el següent fotograma, i *Hungarian Algorithm* per associar-lo. Tot i ser molt eficient a nivell de processament, pateix un problema sever de fragmentació (ID Switches) quan els objectes s'oculten entre ells [18].
- **DeepSORT:** Neix com a evolució directa de SORT per resoldre les pèrdues d'identitat durant les oclusions. La seva principal aportació és la integració d'un mòdul descriptor d'aparença profunda (ReID) basat en una xarxa neuronal. Gràcies a això, DeepSORT assoleix una associació molt més robusta, relacionant els objectes no només per la seva posició física predita, sinó també per les seves característiques visuals [19].
- **Norfair:** És una llibreria de seguiment de codi obert dissenyada específicament per ser molt lleugera i adaptable. A diferència de DeepSORT, Norfair no usa xarxes neuronals pesades per a l'extracció d'aparença, i basa l'associació en funcions de distància heurístiques definides pel mateix usuari. Aquesta manera de funcionar el fa ideal per a entorns de monitoratge controlats o per a execucions en dispositius amb molt poca capacitat de càlcul [20].
- **ByteTrack:** Millora als anteriors no descartant automàticament les deteccions de baixa confiança. En lloc d'eliminar-les, les recupera en un procés d'associació secundari, aconseguint mantenir trajectòries estables durant oclusions complexes [21].

- **BoT-SORT (Robust Associations Multi-Object Tracking):** És actualment un dels algorismes més precisos i robusts. Aquest model millora DeepSORT integrant un sistema de compensació del moviment de la càmera (CMC) i un mòdul ReID molt avançat. Tot i que proporciona una gran estabilitat en la conservació dels IDs, la seva alta càrrega de processament penalitza significativament la quantitat de fotogrames per segon (FPS), dificultant el seu ús en directe de forma pràctica[22].

ÚS DE LA IA GENERATIVA

Per a la redacció d'aquest informe inicial s'ha fet ús de Google Gemini [6], una eina basada en IA generativa amb l'únic propòsit de millorar l'expressió escrita i avaluar diferents opcions de disseny tècnic. Per altra banda, s'ha utilitzat per a crear el codi python a partir de les especificacions d'objectius, fites i sprints creats per a fer el diagrama de Gantt (*Figura 1*) completament personalitzat.

En l'àmbit del desenvolupament de software, la IA s'ha emprat exclusivament com un assistent tècnic per depurar errors (debugging), optimitzar la sintaxi i aportar idees en el disseny dels experiments. Aquest ús s'ha fet sota un criteri estrictament ètic, garantint sempre que la lògica algorítmica i l'autoria del codi recauen íntegrament en l'alumne.

Tot i que ha servit com a suport per reformular textos i analitzar possibles enfocaments metodològics, la direcció del projecte, el contingut i les decisions finals adoptades en aquest document s'han establert de manera completament autònoma i manual.

BIBLIOGRAFIA

- [1] IRTA, "Centre de Control i Avaluació de Porcí," Institut de Recerca i Tecnologia Agroalimentàries. [En línia]. Disponible a: <https://www.irta.cat/centres/control-i-avaluacio-de-porci-cap/>
- [2] Centre de Visió per Computador (CVC), Universitat Autònoma de Barcelona. [En línia]. Disponible a: <https://www.cvc.uab.es/>
- [3] Ministerio de Agricultura, Pesca y Alimentación (MAPA), "Indicadores económicos del sector de la carne de cerdo en cifras 2024," 2024. [En línia]. Disponible a: <https://www.mapa.gob.es/dam/mapa/contenido/ganaderia/temas/produccion-y-mercados-ganaderos/sectores-ganaderos-2/porcino/informacion-del-sector/indicadores-economicos/indicadores--sector-de-la-carne-de-cerdo-en-cifras-2024.pdf>
- [4] Porcat, "La carn de porc representa el 34% de la producció mundial càrnia segons la FAO," 2024. [En línia]. Disponible a: https://www.porcat.org/ca/noticies/la-carn-de-porc-representa-el-34-de-la-produccio-mundial-carnia-segons-la-fao_3282/
- [5] Trello, "Eina de gestió de projectes i tasques," Atlassian. [En línia]. Disponible a: <https://trello.com/>

NOM ESTUDIANT: TÍTOL TREBALL (ABREUJAT SI ÉS MOLT LLARG)

[6] Google, "Gemini: Intel·ligència Artificial Generativa," 2024. [En línia]. Disponible a: <https://gemini.google.com/>

[7] Ultralytics, "Ultralytics Docs: YOLOv8 and Vision AI documentation," 2024. [En línia]. Disponible a: <https://docs.ultralytics.com/>

[8] GitHub, "Plataforma de desenvolupament col·laboratiu i control de versions," 2026. [En línia]. Disponible a: <https://github.com/>

[9] Meta AI, "Segment Anything Model (SAM): A new AI model for image segmentation," 2023. [En línia]. Disponible a: <https://segment-anything.com/>

[10] Meta AI, "Segment Anything Model 2 (SAM 2): Real-time segmentation for video and images," 2024. [En línia]. Disponible a: <https://ai.meta.com/blog/segment-anything-2/>

[11] MIT 6.S191, "Introduction to Deep Learning," Massachusetts Institute of Technology (YouTube Course). [En línia]. Disponible a: https://www.youtube.com/watch?v=al-fdI7S6wCY&list=PLtBw6njQRU-rwp5__7C0oIVt26ZgJG9NI

[12] Kaggle, "Kaggle Learn: Practical Machine Learning and Data Science courses," 2024. [En línia]. Disponible a: <https://www.kaggle.com/learn>

[13] K. He, G. Gkioxari, P. Dollár i R. Girshick, "Mask R-CNN", Proceedings of the IEEE international conference on computer vision, pp. 2961-2969, 2017. [En línia]. Disponible a: <https://arxiv.org/abs/1703.06870>

[14] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu i A. C. Berg, "SSD: Single shot multibox detector", European conference on computer vision (ECCV), pp. 21-37, 2016. [En línia]. Disponible a: <https://arxiv.org/abs/1512.02325>

[15] H. W. Kuhn, "The Hungarian method for the assignment problem", Naval research logistics quarterly, vol. 2, núm. 1-2, pp. 83-97, 1955. [En línia]. Disponible a: <https://doi.org/10.1002/nav.3800020109>

[16] M. A. Kramer, "Nonlinear principal component analysis using autoassociative neural networks", AIChE journal, vol. 37, núm. 2, pp. 233-243, 1991. [En línia]. Disponible a: <https://doi.org/10.1002/aic.690370209>

[17] M. Ye, J. Shen, G. Lin, T. Xiang, L. Shao i S. C. Hoi, "Deep learning for person re-identification: A review and outlook", IEEE transactions on pattern analysis and machine intelligence, 2021. [En línia]. Disponible a: <https://arxiv.org/abs/2001.04193>

[18] A. Bewley, Z. Ge, L. Ott, F. Ramos i B. Upcroft, "Simple online and realtime tracking", 2016 IEEE international conference on image processing (ICIP), 2016. [En línia]. Disponible a: <https://arxiv.org/abs/1602.00763>

[19] N. Wojke, A. Bewley i D. Paulus, "Simple online and realtime tracking with a deep association metric", 2017 IEEE international conference on image processing (ICIP), 2017. [En línia]. Disponible a: <https://arxiv.org/abs/1703.07402>

[20] Tryolabs, "Norfair: Lightweight Python library for adding real-time 2D object tracking to any detector", 2020. [En línia]. Disponible a: <https://github.com/tryolabs/norfair>

[21] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan i X. Wang, "ByteTrack: Multi-object tracking by associating every detection

box", European Conference on Computer Vision (ECCV), 2022. [En línia]. Disponible a: <https://arxiv.org/abs/2110.06864>

[22] N. Aharon, R. Orfaig i B. Z. Bobrovsky, "BoT-SORT: Robust associations multi-object tracking", arXiv preprint arXiv:2206.14651, 2022. [En línia]. Disponible a: <https://arxiv.org/abs/2206.14651>

[23] G. Bradski, "The OpenCV Library", Dr. Dobb's Journal of Software Tools, 2000. [En línia]. Disponible a: <https://opencv.org/>

[24] OpenCV, "Computer Vision Annotation Tool (CVAT)", 2024. [En línia]. Disponible a: <https://www.cvat.ai/>

[25] Meta AI, "Segment Anything Model 3 (SAM 3)", 2025. [En línia]. Disponible a: <https://ai.meta.com/blog/segment-anything-model-3/>